

Tự động hóa Khám phá Chiến lược Đầu tư Định lượng bằng Mô hình Ngôn ngữ Lớn

Hoàng Văn Dương¹ Nguyễn Thế Cường¹
Nguyễn Gia Huy¹

¹Trường Đại học Công Nghệ - Đại học Quốc Gia Hà Nội

23020349@vnu.edu.vn, 23020337@vnu.edu.vn, 23020377@vnu.edu.vn

21 tháng 5 năm 2025

Tóm tắt nội dung

Bài viết giới thiệu một framework ba giai đoạn, tận dụng Mô hình Ngôn ngữ Lớn (LLMs) trong hệ thống *multi-agent* nhằm tự động hóa việc khám phá chiến lược tài chính định lượng và nhận diện rủi ro. Phương pháp này khắc phục hạn chế của các mô hình học sâu truyền thống thông qua: (1) sử dụng LLMs với prompt thiết kế kỹ lưỡng để tạo yếu tố alpha từ dữ liệu đa dạng; (2) hệ thống đánh giá đa tác tử chọn lọc yếu tố theo điều kiện thị trường và chất lượng dự đoán; (3) tối ưu hóa trọng số danh mục theo thời gian. Thử nghiệm tại thị trường Trung Quốc và Mỹ cho thấy hiệu suất vượt trội so với các phương pháp tiêu chuẩn. Hệ thống đạt lợi nhuận tích lũy 53,17% trên chỉ số SSE50¹ (01/2023–01/2024), khẳng định khả năng điều chỉnh rủi ro và thích ứng thị trường hiệu quả.

1 Giới thiệu

Những đột phá gần đây trong công nghệ Mô hình Ngôn ngữ Lớn (LLMs) và các hệ thống *multi-agent* đang phát triển mạnh mẽ, hứa hẹn một cuộc cách mạng trong lĩnh vực tài chính định lượng. Mỗi quan hệ này phát huy khả năng hiểu và tạo văn bản của LLMs, kết hợp với các framework và *multi-agent* mô phỏng động lực thị trường, từ đó hình thành nên các phương pháp quản lý danh mục đầu tư tinh vi ([17]).

LLMs đã phát triển từ vai trò hỗ trợ các công cụ phân tích thành những tác nhân chủ động trong việc ra quyết định tài chính. Ví dụ, BloombergGPT đã chứng tỏ hiệu suất vượt trội trong việc phân tích tâm lý thị trường và giải đáp các câu hỏi chuyên ngành ([38]). Nghiên cứu cho thấy LLMs có khả năng tạo ra các hành động giao dịch hiệu quả bằng cách đặt các xu hướng giá vào ngữ cảnh của tin tức và báo cáo thu nhập ([8]). Song song đó, các hệ thống *multi-agent* cung cấp các phương pháp mạnh mẽ để tối ưu hóa danh mục đầu tư thông qua tương tác phi tập trung. Hệ thống Danh mục đầu tư *multi-agent* (Multi-Agent Portfolio System) đã chứng minh rằng danh mục đầu tư được

¹Chỉ số SSE 50 theo dõi hiệu suất của 50 cổ phiếu blue-chip lớn nhất trên Sở Giao dịch Chứng khoán Thượng Hải.

quản lý bởi các *agent* đạt được lợi nhuận đa dạng hóa tốt hơn với hiệu suất điều chỉnh theo rủi ro được cải thiện ([16]). Các framework này nắm bắt được những động lực thị trường phức tạp như chia sẻ thông tin và kinh doanh chênh lệch giá chiến lược, điều mà các mô hình *agent* đơn lẻ không thể giải quyết ([28]). Việc tích hợp các công nghệ này tạo ra những môi trường tài chính phức tạp, nơi các *agent* được tăng cường bởi LLMs thể hiện hành vi thích ứng. StockAgent là một minh chứng cho phương pháp này, với các *agent* được LLMs hỗ trợ mô phỏng các tính cách nhà đầu tư đa dạng, phản ứng linh hoạt với các sự kiện thị trường [47]. Các cấu trúc phân cấp như FinCon tổ chức các *agent* trong mối quan hệ quản lý-nhà phân tích, tạo điều kiện hợp tác thông qua giao tiếp ngôn ngữ tự nhiên [46]. Sự hội tụ này báo hiệu một tương lai của việc ra quyết định tài chính thông minh, phi tập trung, kết hợp học tập dựa trên dữ liệu với khả năng suy luận giống con người để tạo ra các chiến lược đầu tư mạnh mẽ hơn [45].

Khai thác alpha, quá trình khám phá các tín hiệu giao dịch tạo ra lợi nhuận vượt trội trên thị trường tài chính, đối mặt với ba thách thức chính mà chúng tôi xác định: Tính cứng nhắc của các phương pháp truyền thống, vốn thiếu khả năng thích ứng với thị trường năng động (theo [30]); Thách thức về sự đa dạng và tích hợp dữ liệu, bất chấp những tiến bộ của học máy [6, 43]; và Thích ứng với sự biến động của thị trường, mặc dù đã có những tiến bộ trong dự đoán [41]) và xây dựng chiến lược [?].

framework LLM-driven của nhóm giải quyết những hạn chế này thông qua ba thành phần cốt lõi: Khai thác Alpha Linh hoạt (Flexible Alpha Mining), sử dụng LLMs để trích xuất, phân loại và lọc các yếu tố alpha từ tài liệu tài chính, tổ chức chúng thành các yếu tố động lượng, cơ bản hoặc thanh khoản với tính độc lập đã được thiết lập [41]; Đánh giá Thị trường Đa phương thức *multi-agent* (Multi-agent Multimodal Market Evaluation), thực hiện kiểm định ngược (backtesting) nghiêm ngặt trên các điều kiện thị trường đa dạng, với các *agent* chuyên biệt đánh giá hiệu quả của yếu tố từ nhiều góc độ; và Tối ưu hóa Chiến lược Động (Dynamic Strategy Optimization), triển khai một lớp cổng trọng số (weight gating layer) gán trọng số yếu tố alpha tối ưu dựa trên điều kiện thị trường hiện tại, đảm bảo phát triển chiến lược thích ứng.

Phương pháp luận của chúng tôi tổng hợp các kỹ thuật học máy tiên tiến với kiến thức chuyên môn về tài chính đã được thiết lập để tạo ra một framework liên ngành mạnh mẽ cho việc xác định và tối ưu hóa alpha trên các loại tài sản đa dạng. Nghiên cứu này dựa trên các thực tiễn đầu tư định lượng thực nghiệm, kết nối những tiến bộ lý thuyết với các ứng dụng thực tế trong quản lý danh mục đầu tư.

Những đóng góp chính của nghiên cứu này gồm ba điểm nổi bật: **1)** Một framework mới để xác định các yếu tố alpha công thức bằng LLMs, tận dụng khả năng khám phá của chúng để thiết lập một "Nhà máy Alpha"(Alpha factory) từ thông tin đa phương thức với chức năng cập nhật tăng dần; **2)** Giới thiệu một phương pháp *multi-agent* để quản lý danh mục đầu tư nhằm đánh giá mối quan hệ giữa điều kiện thị trường và các yếu tố alpha, cho phép đánh giá chuyên biệt theo các kịch bản khác nhau; **3)** Tích hợp các kỹ thuật tiên tiến từ học máy và tài chính, thể hiện một bước tiến đáng kể trong việc phát triển các chiến lược đầu tư mạnh mẽ, thích ứng mà không cần sự can thiệp của con người.

Framework được đề xuất cho thấy tính linh hoạt trên các loại tài sản khác nhau, nâng cao tiện ích và hiệu quả thực tế của nó.

2 Xây dựng bài toán

Nhằm thiết lập nền tảng lý thuyết cho nghiên cứu chiến lược yếu tố alpha trong tài chính định lượng. Chúng tôi đề xuất một framework nhằm giải quyết ba thách thức then chốt: hình thức hóa các alpha, tạo *seed alpha* động, và tối ưu hóa chiến lược alpha. Phương pháp kết hợp LLMs và hệ thống *multi-agent* để khắc phục hạn chế của các mô hình truyền thống.

Xét n cổ phiếu trong T giai đoạn giao dịch, mỗi cổ phiếu có m đặc điểm tài chính. Yếu tố alpha tại thời điểm t với cổ phiếu i trong danh mục j được ký hiệu $a_{ij}^{(t)}$ cùng trọng số w_i . Điều kiện thị trường là $M^{(t)}$, và sức mạnh dự đoán được đo bằng Hệ số Thông tin (IC)²:

$$IC = \sigma(u, v) \quad (1)$$

Trong đó, $\sigma(u, v)$ là hệ số tương quan giữa alpha dự đoán u và lợi nhuận thực tế v , phản ánh độ tin cậy của yếu tố alpha.

2.1 Biểu diễn yếu tố Alpha

Thách thức đầu tiên liên quan đến việc biểu diễn hiệu quả các yếu tố alpha bằng các biểu thức toán học nắm bắt được các tín hiệu tài chính có ý nghĩa [21]. Cho các đặc điểm tài chính thô $X_i^{(t)} = \{X_{i1}^{(t)}, X_{i2}^{(t)}, \dots, X_{im}^{(t)}\}$ cho mỗi cổ phiếu i tại thời điểm t (chẳng hạn như giá, khối lượng và biến động), chúng tôi xác định các yếu tố alpha thông qua hai loại toán tử:

Toán tử Cắt ngang (Cross-Section Operators) f_{cs} : Các toán tử này xử lý dữ liệu từ một khoảng thời gian duy nhất, nắm bắt các mối quan hệ tức thời giữa các biến tài chính:

$$a_i^{(t)} = f_{cs}(X_i^{(t)}) \quad (2)$$

Toán tử Chuỗi thời gian (Time-Series Operators) f_{ts} : Các toán tử này phân tích dữ liệu trải dài nhiều khoảng thời gian, xác định các xu hướng và mô hình thời gian:

$$a_i^{(t)} = f_{ts}(X_i^{(t)}, X_i^{(t-1)}, \dots, X_i^{(t-n)}) \quad (3)$$

Seed alpha cho cổ phiếu i trong danh mục j tại thời điểm t được xây dựng như sau:

$$a_{ij}^{(t)} = w_{cs} \cdot f_{cs}(X_i^{(t)}) + w_{ts} \cdot f_{ts}(X_i^{(t)}, \dots, X_i^{(t-n)}) \quad (4)$$

trong đó w_{cs} và w_{ts} là các trọng số được gán cho các thành phần cắt ngang và chuỗi thời gian tương ứng. Biểu diễn này cho phép kết hợp linh hoạt các tín hiệu tài chính khác nhau, cho phép tạo ra các yếu tố alpha phức tạp và tinh tế.

2.2 Khai thác và Lựa chọn Alpha

Thách thức thứ hai giải quyết những hạn chế của các phương pháp khai thác alpha truyền thống, vốn thường không thích ứng được với điều kiện thị trường thay đổi. Chúng tôi xây dựng một phương pháp lựa chọn động để xác định các alpha phù hợp nhất với điều kiện thị trường hiện tại bằng cách sử dụng hai cơ chế đánh giá bổ sung:

²IC là viết tắt của Information Coefficient (Hệ số Thông tin).

Đánh giá Điểm Tin cậy (Confidence Score Evaluation): Đánh giá độ tin cậy thống kê của mỗi yếu tố alpha:

$$\theta_{ij} = E[IC(a_{ij}^{(t)} | M^{(t)})] \quad (5)$$

trong đó θ_{ij} biểu thị điểm tin cậy cho alpha a_{ij} , và $E[\cdot]$ biểu thị giá trị kỳ vọng. Điểm tin cậy cao hơn cho thấy hiệu suất nhất quán hơn trên các môi trường thị trường khác nhau.

Đánh giá Sở thích Rủi ro (Risk Preference Evaluation): Kiểm tra các đặc điểm rủi ro của mỗi yếu tố alpha:

$$\rho_{ij} = f_{\text{risk}}(a_{ij}^{(t)}, M^{(t)}) \quad (6)$$

trong đó ρ_{ij} biểu thị điểm rủi ro và f_{risk} là một hàm đánh giá mức độ hoạt động của alpha trong các kịch bản rủi ro khác nhau.

Tập hợp seed alpha tối ưu được lựa chọn bằng cách xem xét cả đánh giá tin cậy và rủi ro:

$$\alpha_{ij}^* = \arg \max_{a_{ij}} [w_c \cdot \theta_{ij} + w_r \cdot \rho_{ij}] \quad (7)$$

trong đó w_c và w_r là các trọng số được gán cho điểm tin cậy và điểm rủi ro tương ứng, phản ánh tầm quan trọng tương đối của chúng trong quá trình lựa chọn.

2.3 Tối ưu hóa chiến lược

Thách thức thứ ba liên quan đến việc kết hợp các alpha đã chọn thành một chiến lược đầu tư hiệu quả. Chiến lược alpha cuối cùng được xác định là một sự kết hợp có trọng số của các alpha tối ưu từ mỗi danh mục:

$$\alpha^{(t)} = \sum_{j=1}^k w_j \cdot \alpha_{ij}^{(t)} \quad (8)$$

trong đó w_j biểu thị trọng số được gán cho danh mục j , và k là tổng số danh mục alpha. Các trọng số này được điều chỉnh động dựa trên tình trạng thị trường hiện tại để tối đa hóa hiệu suất chiến lược trong khi quản lý rủi ro danh mục đầu tư tổng thể. Việc tối ưu hóa này hoàn thiện framework của chúng tôi, biến đổi dữ liệu tài chính thô thành một chiến lược giao dịch mạnh mẽ có thể thích ứng với môi trường thị trường thay đổi.


3 Phương pháp

3.1 Tổng quan về Framework

framework của chúng tôi bao gồm ba thành phần liên kết chặt chẽ (xem Hình 1): Nhà máy seed alpha (SAF - Seed Alpha Factory), quy trình ra quyết định *multi-agent*, và cơ chế tối ưu hóa trọng số. Giai đoạn đầu tiên sử dụng LLMs để phân tích và phân loại các tài liệu nghiên cứu tài chính đa phương thức, từ đó xây dựng một SAF toàn diện. Khả năng xử lý các tập dữ liệu đa dạng của LLMs cho phép tạo ra một tập hợp seed alpha mạnh mẽ, được phân loại thành các nhóm độc lập, phù hợp với các nguyên tắc khai thác alpha tài chính đã được thiết lập [25]. Giai đoạn thứ hai triển khai một quy trình đánh

giá *multi-agent* đa phương thức, kết hợp các quan điểm rủi ro đa dạng, nhằm nâng cao khả năng thích ứng của chiến lược trên các điều kiện thị trường khác nhau. Giai đoạn này tạo ra một tập hợp alpha tối ưu, phù hợp với trạng thái thị trường hiện tại và sở thích rủi ro. Giai đoạn cuối cùng sử dụng các phương pháp học sâu để tối ưu hóa trọng số của các alpha đã chọn, từ đó xây dựng một chiến lược tổng thể mạch lạc.

Kiến trúc động của framework cho phép tinh chỉnh liên tục thông qua các bản cập nhật tăng dần cho SAF khi có nghiên cứu mới xuất hiện và điều kiện thị trường thay đổi. Khả năng thích ứng này đảm bảo chiến lược duy trì sự phù hợp và mạnh mẽ theo thời gian. Tính linh hoạt của phương pháp luận cho phép áp dụng cho bất kỳ thị trường có cấu trúc nào trên toàn cầu, sao chép và tăng cường hiệu quả các phương pháp nghiên cứu đầu tư chuyên nghiệp.



Hình 1: Tổng quan về quy trình tạo chiến lược gồm ba thành phần: một Nhà máy seed alpha (Seed Alpha Factory) được xây dựng bằng LLM, một hệ thống ra quyết định *multi-agent*, và một phương pháp tối ưu hóa trọng số cho chiến lược tổng thể (CS là viết tắt của điểm tin cậy; RP là viết tắt của sở thích rủi ro).

3.2 Tạo seed alpha dựa trên LLM

Giai đoạn đầu tiên triển khai một quy trình lọc và phân loại dựa trên LLM cho các nghiên cứu liên quan đến alpha. Chúng tôi sử dụng mô hình GPT-4o để thực hiện các tác vụ này trên một kho dữ liệu nghiên cứu tài chính đa dạng. Tập dữ liệu ban đầu của chúng tôi bao gồm 11 tài liệu, bao gồm cả khía cạnh lý thuyết và ứng dụng của nghiên cứu khai thác alpha (chi tiết trong Phụ lục A.2). Thông qua quy trình này, hệ thống đã tạo ra 9 danh mục riêng biệt chứa 100 seed alpha. Phương pháp này tăng cường khả năng của mô hình trong việc trích xuất các chi tiết và mối quan hệ phức tạp trong nghiên cứu tài chính, dẫn đến một SAF mạnh mẽ và đa dạng hơn.

Đầu ra là một tập hợp seed alpha có cấu trúc, được phân loại thành các lĩnh vực tài chính riêng biệt như Động lượng (Momentum), Đảo chiều Trung bình (Mean Reversion), và Phân tích Cơ bản (Fundamental analysis), v.v. Mỗi danh mục bao gồm các chỉ định alpha cụ thể và các công thức thực thi tương ứng được suy ra từ phân tích của LLM (tham khảo Phụ lục A.3). Đầu ra có cấu trúc này tạo nền tảng cho các giai đoạn xử lý tiếp theo.

3.3 Đánh giá *multi-agent* đa phương thức

Giai đoạn thứ hai triển khai một hệ thống đánh giá và lựa chọn toàn diện các yếu tố alpha thông qua một hệ thống đa phương thức và *multi-agent*. Hệ thống của chúng tôi

tích hợp năm loại dữ liệu đa phương thức (chi tiết trong Phụ lục A.4), bao gồm văn bản, số, hình ảnh, âm thanh và video. Kiến trúc *multi-agent* bao gồm hai *agent*: *agent* Điểm Tin cậy (CSA - Confidence Score Agent) và *agent* Sở thích Rủi ro (RPA - Risk Preference Agent). Các yếu tố alpha được chọn sẽ trải qua quá trình kiểm định ngược (backtesting) nghiêm ngặt bằng cách sử dụng dữ liệu thị trường lịch sử, với các chỉ số đánh giá chính bao gồm IC [9], xem phương trình 1) và Tỷ lệ Sharpe [27], phương trình 9:

$$\text{Tỷ lệ Sharpe} = \frac{E[R(\alpha^{(t)}) - R_f]}{\sqrt{\text{Var}[R(\alpha^{(t)})]}} \quad (9)$$

trong đó $R(\alpha^{(t)})$ biểu thị lợi nhuận của chiến lược và R_f biểu thị lãi suất phi rủi ro. Chúng tôi đã phát triển một thuật toán Lựa chọn Alpha Dựa trên Danh mục (chi tiết trong Phụ lục A.5, Thuật toán 1) để tự động hóa việc lựa chọn. Thuật toán này xác định và lựa chọn một cách có hệ thống các alpha từ các danh mục khác nhau dựa trên điểm tin cậy của chúng, đảm bảo lựa chọn nghiêm ngặt các yếu tố đáp ứng ngưỡng tin cậy trên tất cả các danh mục trong khi duy trì sự đa dạng của danh mục.

3.4 Tối ưu hóa Trọng số

Giai đoạn cuối cùng sử dụng một mạng Perceptron Đa lớp (MLP) 3 lớp để tối ưu hóa trọng số của các seed alpha đã chọn bằng cách ánh xạ các tính toán alpha lịch sử với lợi suất trong tương lai [4]. Kiến trúc bao gồm một lớp đầu vào xử lý các giá trị alpha hàng ngày, một lớp ẩn với mười nút kích hoạt bằng ReLU, và một lớp đầu ra một nút để dự đoán lợi suất.

Trong quá trình huấn luyện, mạng sử dụng lan truyền ngược (backpropagation) và giảm độ dốc (gradient descent) để giảm thiểu hàm mất mát, định lượng sự khác biệt giữa lợi suất dự đoán và lợi suất thực tế. Chúng tôi sử dụng một tập dữ liệu xác thực riêng biệt để đảm bảo khả năng khái quát hóa của mô hình và tránh trạng thái quá mức (overfitting). Mạng Nơ-ron Sâu (DNN) xử lý dữ liệu đầu vào thông qua lớp ẩn, biến đổi nó bằng các trọng số và độ lệch đã học, và tạo ra đầu ra cuối cùng thông qua trọng số, độ lệch và hàm kích hoạt của lớp đầu ra.

Phương pháp luận này thiết lập một framework mạnh mẽ để dự đoán lợi suất trong tương lai dựa trên các giá trị alpha lịch sử, chứng minh hiệu quả của các kỹ thuật học sâu trong việc tối ưu hóa trọng số alpha và nâng cao hiệu suất chiến lược đầu tư. Thuật toán 2 (trong Phụ lục A.6) cung cấp một đặc tả hình thức của framework hoàn chỉnh của chúng tôi, minh họa luồng logic từ xử lý dữ liệu đa phương thức thông qua đánh giá *multi-agent* đến tối ưu hóa trọng số cuối cùng.

4 Thực nghiệm


Nghiên cứu của chúng tôi nhằm mục đích phát triển một framework khai thác alpha LLM-driven toàn diện, hoạt động mà không cần sự can thiệp của con người. framework này có khả năng xử lý thông tin đa phương thức và thích ứng với các điều kiện thị trường thay đổi một cách độc đáo. Để xác nhận tính hiệu quả của framework, chúng tôi đã tiến hành một loạt các thí nghiệm.

4.1 Tập dữ liệu

Nghiên cứu của chúng tôi tập trung vào dữ liệu tài chính từ thị trường Trung Quốc và Hoa Kỳ, đặc biệt nhắm vào Chỉ số SSE 50. Bảng 1 cho thấy tập dữ liệu thử nghiệm, bao gồm sáu đặc điểm chính làm đầu vào ban đầu cho các yếu tố Alpha: giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa, khối lượng giao dịch (OHLCV) và giá trung bình theo khối lượng (VWAP). Để đảm bảo đánh giá nghiêm ngặt và hiệu suất mô hình mạnh mẽ, các thí nghiệm tích hợp các báo cáo tài chính và hiệu suất yếu tố của 50 công ty cấu thành Chỉ số SSE 50, cung cấp một cái nhìn toàn diện về thị trường [19]. Việc đánh giá xem xét các tập dữ liệu khác nhau, bao gồm các báo cáo tài chính từ các giai đoạn được chỉ định và hiệu suất các chỉ số của các yếu tố Alpha khác nhau.

Bảng 1: Tóm tắt Tập dữ liệu Thử nghiệm

Khía cạnh	Chi tiết
Đặc điểm Chính	Mở, Cao, Thấp, Đóng, Khối lượng, VWAP
Yếu tố Alpha	Các yếu tố tùy chỉnh dựa trên giá, khối lượng, tỷ số tài chính, trung bình động, phân tích tâm lý
Báo cáo Tài chính	Báo cáo hàng quý và hàng năm từ các công ty thành phần của Chỉ số
Khoảng thời gian	Tháng 1 năm 2019 - Tháng 6 năm 2024
Phạm vi Thị trường	Chỉ số SSE50, CSI300, SP500
Tiêu chí Đánh giá	Mối quan hệ nhân quả, hiệu suất yếu tố Alpha, độ mạnh mẽ của mô hình



Hình 2: Alpha Được chọn Phụ thuộc vào Bối cảnh Khác nhau. Hình này minh họa cách framework lựa chọn các alpha khác nhau (ví dụ: dựa trên động lượng so với dựa trên biến động) tùy thuộc vào dữ liệu đầu vào và điều kiện thị trường của các giai đoạn khác nhau (Trường hợp 1 và Trường hợp 2).

4.2 Trích xuất kiến thức đa phương thức và Khám phá Alpha thích ứng

Chúng tôi triển khai một kiến trúc prompt (minh họa trong Hình 2) tích hợp thông tin thị trường đa phương thức vào LLMs để trích xuất kiến thức toàn diện và lựa chọn seed alpha. Kiến trúc này tích hợp dữ liệu tài chính dạng văn bản, báo cáo tài chính công ty dạng số và biểu đồ giao dịch trực quan để cung cấp phân tích thị trường tổng thể. Cơ chế phân tích theo ngữ cảnh của chúng tôi điều chỉnh động các tham số dựa trên xu hướng thị trường hiện hành và hiệu suất ngành. Xác thực thực nghiệm cho thấy khả năng thích ứng của framework trên các điều kiện thị trường khác nhau. Trong Trường hợp 1, khi phân tích dữ liệu SSE50 từ tháng 1 năm 2023 đến tháng 12 năm 2023, mô hình đã chọn các chỉ báo dựa trên động lượng và khối lượng như động lượng giá, RSI và MACD. Ngược lại, trong Trường hợp 2, khi xử lý khoảng thời gian từ tháng 1 năm 2022 đến tháng 12 năm 2022, mô hình ưu tiên các yếu tố biến động và kinh tế, bao gồm ATR, Bollinger Bands và các chỉ báo lợi nhuận gộp.

Những kết quả này xác nhận khả năng của framework trong việc thích ứng động với các điều kiện thị trường thay đổi thông qua tích hợp dữ liệu đa phương thức hiệu quả. Khả năng thích ứng này cho phép xác định các alpha phù hợp với thị trường, nâng cao tính mạnh mẽ của chiến lược trên các môi trường thị trường đa dạng.

Bảng 2: IC Comparison of mean & selected

	Momentum	Mean Reversion	Volatility	Fundamental	Growth
Mean IC of SAF	0.0092	0.0135	0.0177	0.0118	0.0146
Mean IC of Selected SAF	0.0208	0.0187	0.0258	0.0192	0.0217

4.3 Hiệu suất so với các yếu tố Alpha truyền thống


Khi đánh giá hiệu suất của các tín hiệu seed alpha đã chọn, chỉ số chính là IC (Hệ số Thông tin). Chúng tôi đã đánh giá năm loại alpha phổ biến nhất: Động lượng, Đảo chiều Trung bình, Biến động, Cơ bản và Tăng trưởng. Kết quả trong Bảng 2 cho thấy framework LLM-driven của chúng tôi liên tục đạt được các giá trị IC trung bình cao hơn trên tất cả các loại, đặc biệt là về Biến động và Cơ bản, cho thấy hiệu quả giao dịch vượt trội so với các yếu tố alpha gốc.

4.4 Đánh giá Hiệu suất của Framework Alpha Tích hợp thông qua việc so sánh với tham chiếu chuẩn

Bảng 3 trình bày một ví dụ về sự kết hợp của 12 alpha được tạo bởi framework của chúng tôi, được đánh giá trên tập hợp cổ phiếu SSE50. Bảng này chi tiết các seed alpha được LLM chọn từ mỗi danh mục, cùng với trọng số tương ứng và giá trị IC (định nghĩa trong phương trình 1). Giá trị IC của tổ hợp trọng số khá cao, ở mức -0.0587. Mặc dù một số seed alpha riêng lẻ có giá trị IC tương đối thấp, việc loại bỏ chúng dẫn đến sự sụt giảm đáng kể trong trọng số tổ hợp được đào tạo lại, cho thấy vai trò quan trọng của chúng trong hiệu suất tổng thể. Ví dụ, nếu chúng ta loại bỏ alpha #6, tổ hợp trọng số sẽ giảm xuống -0.055; một khi chúng ta loại bỏ alpha #11, tổ hợp trọng số sẽ giảm xuống chỉ còn 0.0491. Điều này cho thấy tập hợp seed alpha được LLM chọn phối hợp hiệu quả, cung cấp sức mạnh dự đoán mạnh mẽ [48].

Bảng 3: Kiểm tra Kết hợp 12 Alpha trên SSE50 năm 2023

#	Alpha	Trọng số	IC(SSE50)
1	(CLOSE - DELAY(CLOSE, 14))	-0.1459	0.0209
2	(RSI - DELAY(RSI, 14))	-1.0265	-0.0225
3	(CLOSE - DELAY(SMA(CLOSE, 14), 7))	-0.1978	0.0193
4	(MA(CLOSE, 20) - CLOSE)	0.0556	-0.0186
5	(SMA(CLOSE, 20) - CLOSE)	-0.945	-0.0186
6	(MAX(HIGH, 20) - CLOSE)	-0.4053	-0.0185
7	(100-RSI)	-0.3199	0.0194
8	(BOLL_UP - BOLL_DOWN) / SMA(CLOSE, 20)	3.6186	0.0278
9	STD(CLOSE, 10) / STD(CLOSE, 50)	-0.183	0.0236
10	VOLUME/MARKET_CAP	-3.2145	-0.0194
11	VOLUME * CLOSE	-0.0058	0.0187
12	(EPS/DELAY(EPS, 1) - 1)	-1.8351	-0.0215
Tổ hợp Trọng số			-0.0587



Hình 3: Kết quả Backtest Lợi nhuận Tích lũy trên SSE50. Đường cong thể hiện giá trị ròng của các phương pháp khác nhau trong giai đoạn thử nghiệm.

Để giải quyết câu hỏi liệu chiến lược tổng thể, kết hợp framework LLM-driven và chấm điểm tin cậy, có thể liên tục đánh bại thị trường hay không, chúng tôi đã tiến hành một thử nghiệm backtest sử dụng một phương pháp đầu tư đơn giản trong giai đoạn từ tháng 1 năm 2023 đến tháng 1 năm 2024 (huấn luyện: tháng 1 năm 2021 - tháng 6 năm 2022; xác thực: tháng 7 năm 2022 - tháng 12 năm 2022), trên tập dữ liệu SSE50. Chúng tôi đã triển khai framework để xây dựng danh mục đầu tư (chi tiết trong Phụ lục A.8). Diễn biến giá trị ròng của các chiến lược tương ứng trong giai đoạn thử nghiệm được thể hiện trong Hình 3, và ma trận so sánh được trình bày trong Bảng 4. Mặc dù không tối ưu hóa rõ ràng cho lợi nhuận tuyệt đối, framework của chúng tôi cho thấy hiệu suất ấn tượng trong thử nghiệm backtest, đạt được lợi nhuận cao nhất so với các phương pháp khác. Lợi nhuận tích lũy của chúng tôi cho thử nghiệm backtest năm 2023 đạt 53,17% dương trong khi hiệu suất chỉ số là -11,73%. Chúng tôi cũng thực hiện so sánh với 4 phương pháp thống kê tiên tiến và 2 phương pháp dựa trên LLM. Chiến lược framework vượt trội đáng kể so với tất cả các đối thủ cạnh tranh với lợi nhuận cao nhất (53,17%),

các chỉ số điều chỉnh rủi ro tốt nhất (Sharpe: 0,287, Sortino³: 0,208, Calmar⁴: 1,052), và độ biến động thấp nhất (0,762%). Các phương pháp dựa trên LLM là FinCon [46] và SEP [14] cho thấy thành công vừa phải (22,47%, 17,89%), trong khi các phương pháp học máy thông thường mang lại lợi nhuận cận biên (XGBoost 9,53%, [3]). Đáng chú ý, tất cả các chiến lược được đánh giá đều vượt qua tiêu chuẩn SSE50, vốn thể hiện hiệu suất âm (-13,22%). Phương pháp này chứng minh hiệu quả của framework LLM-driven của chúng tôi trong việc liên tục vượt trội so với các tiêu chuẩn thị trường thông qua sự thích ứng động với các điều kiện thay đổi.

Bảng 4: So sánh Hiệu suất của các Chiến lược Giao dịch

Chiến lược	Lợi nhuận cuối cùng (%)	Tỷ lệ Sharpe	Biến động (%)	Tỷ lệ Sortino	Tỷ lệ Calmar
Của nghiên cứu	53.173	0.287	0.762	0.208	1.052
XGBoost ([3])	9.532	0.038	1.019	0.067	0.103
LightGBM ([13])	7.125	0.030	0.993	0.053	0.066
MLP	3.110	0.013	0.960	0.023	0.043
PPO_filter ([26])	2.865	0.013	0.886	0.024	0.017
FinCon ([46])	22.474	0.077	1.196	0.126	0.232
SEP ([14])	17.891	0.060	1.217	0.103	0.157
SSE 50	-13.220	-0.063	0.859	-0.111	-0.043

4.5 Độ mạnh mẽ của Framework qua các giai đoạn của thị trường

Chúng tôi đã tiến hành xác thực chéo theo thời gian và chéo thị trường nghiêm ngặt bằng cách sử dụng hai bộ dữ liệu toàn diện: các thành phần CSI300⁵ (truy cập qua Tushare API) và các thành phần SP500⁶ (truy cập qua nền tảng CRSP) kéo dài từ tháng 1 năm 2019 đến tháng 12 năm 2023. Bộ dữ liệu của chúng tôi kết hợp các chỉ số giá OHLCV hàng ngày, báo cáo tài chính hàng quý và các chỉ số kinh tế vĩ mô liên quan để cho phép xây dựng yếu tố alpha mạnh mẽ. Để đảm bảo tính toàn vẹn về phương pháp luận, chúng tôi đã phân chia một cách có hệ thống bộ dữ liệu thành các tập con huấn luyện, xác thực

³Tỷ lệ Sortino tính toán lợi nhuận vượt trội trên mỗi đơn vị độ lệch giảm, chỉ đánh giá độ biến động lợi nhuận âm.

⁴Tỷ lệ Calmar chia lợi nhuận hàng năm cho mức sụt giảm tối đa, đo lường phần thưởng so với rủi ro.

⁵Chỉ số CSI300 theo dõi 300 công ty lớn nhất được niêm yết trên các sàn giao dịch Thượng Hải và Thâm Quyển của Trung Quốc.

⁶Chỉ số SP500 đo lường hiệu suất của 500 công ty lớn của Hoa Kỳ được giao dịch trên các sàn giao dịch chứng khoán Mỹ.

và thử nghiệm với sự phân đoạn theo thời gian chính xác như được trình bày chi tiết trong Bảng 5. Thiết kế thử nghiệm này tạo điều kiện cho việc đánh giá toàn diện khả năng khái quát hóa của framework của chúng tôi trên các môi trường thị trường và bối cảnh thời gian khác nhau.

Chúng tôi đã sử dụng phân vùng thời gian nhất quán trên các thị trường A-share của Trung Quốc và thị trường Hoa Kỳ để cho phép phân tích so sánh trực tiếp. Những phát hiện của chúng tôi cho thấy hiệu suất mạnh mẽ của framework trên các môi trường thị trường đa dạng. Từ Bảng 6 cho thấy trên thị trường A-Share của Trung Quốc, chiến lược đã tạo ra alpha đáng kể với các thành phần CSI300, đặc biệt là trong nửa đầu năm 2023 (lợi nhuận hàng năm 192,27

Bằng chứng thực nghiệm chứng minh cả sự bền bỉ theo thời gian và tính mạnh mẽ trên các thị trường của những phát hiện của chúng tôi, với các đặc điểm ngược chu kỳ đặc biệt có lợi xuất hiện trong các giai đoạn thị trường khó khăn. framework cho thấy khả năng tạo alpha nhất quán trên các kiến trúc thị trường, khuôn khổ pháp lý và mô hình hành vi nhà đầu tư đa dạng, thiết lập khả năng ứng dụng rộng rãi của nó. Cụ thể, mô hình duy trì quỹ đạo vượt trội ổn định qua các điều kiện thị trường tăng giá, giảm giá và đi ngang (chi tiết trong Phụ lục A.9), từ đó xác nhận tính toàn vẹn cấu trúc và khả năng thích ứng của nó với các môi trường kinh tế vĩ mô khác nhau.

Bảng 5: Các giai đoạn Huấn luyện, Xác thực và Thử nghiệm cho CSI300 và SP500

Tài sản	Giai đoạn Huấn luyện	Giai đoạn Xác thực	Giai đoạn Thử nghiệm
CSI300	Tháng 1 2019-Tháng 6 2020	Tháng 7-Tháng 12 2020	Tháng 1-Tháng 6 2021
	Tháng 1 2020-Tháng 6 2021	Tháng 7-Tháng 12 2021	Tháng 1-Tháng 6 2022
	Tháng 1 2021-Tháng 6 2022	Tháng 7-Tháng 12 2022	Tháng 1-Tháng 6 2023
SP500	Tháng 1 2019-Tháng 6 2020	Tháng 7-Tháng 12 2020	Tháng 1-Tháng 6 2021
	Tháng 1 2020-Tháng 6 2021	Tháng 7-Tháng 12 2021	Tháng 1-Tháng 6 2022
	Tháng 1 2021-Tháng 6 2022	Tháng 7-Tháng 12 2022	Tháng 1-Tháng 6 2023

Bảng 6: Kết quả Hiệu suất Backtest qua các Cửa sổ Thời gian Khác nhau

Cửa sổ Thời gian	Lợi nhuận Hàng năm (%)		Lợi nhuận Tích lũy (%)		Max DD (%)	
	Chiến lược	Chỉ số	Chiến lược	Chỉ số	Chiến lược	Chỉ số
<i>Chiến lược của chúng tôi so với CSI300</i>						
Th1-Th6 2021	29.70	7.31	11.91	3.10	-19.40	-10.86
Th1-Th6 2022	12.78	-30.37	5.29	-14.37	-24.01	-28.59
Th1-Th6 2023	192.27	9.13	59.03	3.85	-17.03	-8.44
<i>Chiến lược của chúng tôi so với SP500</i>						
Th1-Th6 2021	93.61	29.67	35.19	12.59	-7.89	-4.23
Th1-Th6 2022	2.77	-44.22	1.25	-23.39	-20.55	-23.51
Th1-Th6 2023	118.24	35.22	42.78	14.76	-11.52	-7.75

Lưu ý: Max DD = Mức sụt giảm tối đa.

4.6 Nghiên cứu Loại bỏ thành phần (Ablation Study)

Nghiên cứu loại bỏ thành phần của chúng tôi đánh giá một cách có hệ thống sự đóng góp của *agent* Điểm Tin cậy (CSA) và *agent* Sở thích Rủi ro (RPA) trong một framework

multi-agent. Chúng tôi đánh giá ba cấu hình của mỗi loại, sử dụng dữ liệu chỉ số SSE50 (2010-2022) và đo lường hiệu suất bằng IC (phương trình 1) và Tỷ lệ Sharpe (phương trình 9).

Bảng 7 cho thấy mô hình hoàn chỉnh đạt được hiệu suất vượt trội, với IC ngoài mẫu là 0,047 và Tỷ lệ Sharpe là 1,94 (trong bảng là 1.94, nhưng trong text trước đó là 1.73. Giữ theo bảng). Việc loại bỏ CSA gây ra sự suy giảm đáng kể, làm giảm IC ngoài mẫu 31,9

Phân tích này xác nhận rằng cả hai thành phần đều nâng cao sự ổn định hiệu suất, với CSA cung cấp chức năng đặc biệt quan trọng trong các điều kiện thị trường bất lợi.

Bảng 7: Kết quả nghiên cứu loại bỏ thành phần: tác động của các thành phần *agent* lên các chỉ số hiệu suất

Cấu hình Mô hình	IC (Trong mẫu)	IC (Ngoài mẫu)	Tỷ lệ Sharpe
Mô hình Đầy đủ	0.059	0.047	1.94
Không có Điểm Tin cậy	0.054	0.032	1.51
Không có Sở thích Rủi ro	0.056	0.039	1.34

Bảng 8: Hiệu suất qua các chế độ thị trường

Cấu hình Mô hình	Thị trường Tăng	Thị trường Giảm	Thị trường Đi ngang
Mô hình Đầy đủ	0.051	0.042	0.045
Không có Điểm Tin cậy (CSA)	0.046	0.021	0.029
Không có Sở thích Rủi ro (RPA)	0.049	0.028	0.037

4.6.1 Nghiên cứu độ nhạy

Nhóm đã phân tích độ nhạy của framework đối với trọng số *agent* và các siêu tham số mạng nơ-ron. Tỷ lệ trọng số CSA & RPA là 0,6/0,4 mang lại hiệu suất vượt trội qua các chế độ thị trường, đặc biệt là trong các thị trường giảm giá (Sharpe: 10,37), cho thấy khả năng phục hồi tốt hơn trước những thay đổi của chế độ (Bảng 9). Cấu hình mạng nơ-ron tối ưu (10 Hidden nodes, Learning rate: 0,001, batch size: 32, chính quy hóa: 0,001) đạt được tỷ lệ Sharpe là 13,33, với hiệu suất đặc biệt nhạy cảm với cường độ chính quy hóa (Bảng 10).

Phân tích cho thấy hành vi phụ thuộc vào chế độ qua các điều kiện thị trường và độ nhạy quan trọng đối với cường độ chính quy hóa. Cấu hình tối ưu đạt được tỷ lệ Sharpe tổng thể mạnh mẽ là 11,39.

5 Công trình liên quan

Các alpha công thức trong đầu tư định lượng đại diện cho các chiến lược có hệ thống, dựa trên quy tắc nhằm tạo ra lợi nhuận vượt trội bằng cách khai thác các mô hình thị trường và sự kém hiệu quả cụ thể (theo [12]). Các chiến lược này sử dụng nhiều phương pháp luận khác nhau, bao gồm lập trình di truyền liên quan đến các đột biến cấu trúc và số học để tạo ra các alpha mới (tham khảo [5]), các toán tử chuỗi thời gian nâng cao với thông tin tương hỗ làm thước đo thể lực (theo [20]), và đồ thị thuật toán cho các dự đoán

Bảng 9: Độ nhạy với Cấu hình Trọng số *agent*

Trọng số		Tỷ lệ Sharpe		
Tin cậy	Rủi ro	Thị trường Tăng	Thị trường Giảm	Tổng thể
1.0	0.0	4.32	6.60	8.10
0.8	0.2	-3.41	-7.23	-2.68
0.6	0.4	8.70	10.37	11.39
0.5	0.5	-0.49	-1.62	-5.10
0.4	0.6	-4.27	-4.41	-8.04
0.2	0.8	5.68	8.51	9.00
0.0	1.0	-0.61	1.78	-4.35

Bảng 10: Độ nhạy với các Siêu tham số Mạng Nơ-ron

Nút Ấn	Tốc độ Học	Kích thước Lô	Tham số Chính quy hóa	Tỷ lệ Sharpe
5	0.001	32	0.001	9.69
10	0.001	32	0.001	13.33
20	0.001	32	0.001	6.93
10	0.0005	32	0.001	7.03
10	0.002	32	0.001	5.13
10	0.001	16	0.001	6.26
10	0.001	64	0.001	4.25
10	0.001	32	0.0005	-1.88
10	0.001	32	0.002	-6.91

phức tạp hơn (tham khảo [6]). Các phương pháp học máy sử dụng các kiến trúc mạng nơ-ron như LSTM (Long Short-Term Memory, theo [10]) và các mô hình Transformer (theo [33]), trong khi các mô hình cây quyết định như XGBoost (theo [3]) và LightGBM (theo [13]) mang lại lợi thế về khả năng diễn giải. Nghiên cứu gần đây tập trung vào việc tích hợp các nguồn dữ liệu phi tiêu chuẩn, như được chứng minh bởi REST (theo [40]) và HIST (theo [39]).

Sự phát triển của các LLMs miền chung đã thúc đẩy sự quan tâm đến các LLMs Tài chính (Fin-LLM), mặc dù lĩnh vực chuyên biệt này vẫn còn non trẻ (tham khảo [24, 42, 51]). Các LLMs nguồn mở như LLaMA (theo [31]), BLOOM (theo [34]), và Flan-T5 (theo [35]) cung cấp tính linh hoạt nhưng có thể hoạt động kém hơn các lựa chọn thay thế độc quyền. Các LLMs tài chính được tinh chỉnh cho thấy khả năng hiểu biết chuyên ngành được nâng cao, tuy nhiên hiệu suất tạo sinh của chúng cho thấy sự cần thiết phải cải thiện các bộ dữ liệu chuyên ngành (tham khảo [18, 14]).

Các LLMs đa phương thức đã cho thấy tiềm năng đáng kể trong bối cảnh đầu tư bằng cách xử lý các loại dữ liệu đa dạng (theo [15]), phát triển các chiến lược giảm thiểu biến động thị trường (theo [11]), và phân tích dữ liệu văn bản để đánh giá tâm lý nhà đầu tư (tham khảo [50]). Các hệ thống LLM *multi-agent* nâng cao khả năng phân tích thị trường bằng cách tận dụng các bộ dữ liệu khổng lồ để diễn giải các báo cáo tài chính và tâm lý thị trường (theo [49]), mô phỏng các kịch bản thị trường khác nhau (tham khảo [29]), và tạo điều kiện thử nghiệm song song các chiến lược đa dạng (theo [37]). Việc triển khai đặt ra những cân nhắc quan trọng về tính minh bạch, trách nhiệm giải

trình và giảm thiểu sai lệch (tham khảo [46, 23]).

6 Kết luận

Trong bài báo này, chúng tôi đã đề xuất một framework đầu tư định lượng mới, tích hợp LLMs và kiến trúc *multi-agent* để giải quyết sự bất ổn trong các phương pháp truyền thống. Hệ thống của chúng tôi tạo ra các yếu tố alpha đa dạng từ dữ liệu tài chính đa phương thức, xây dựng các *agent* giao dịch được hiệu chỉnh theo rủi ro, và sử dụng một cơ chế học sâu để điều chỉnh trọng số *agent* một cách động dựa trên điều kiện thị trường.

Kết quả thực nghiệm đã xác nhận tính hiệu quả của framework trên các thị trường Trung Quốc và Hoa Kỳ. framework của chúng tôi cho thấy hiệu suất vượt trội đáng kể so với các phương pháp tạo alpha hiện đại (SOTA) và các chỉ số chuẩn trên các chỉ số tài chính chính. Công trình này mở rộng thành công khả năng của LLMs sang giao dịch định lượng, tạo ra một kiến trúc có thể mở rộng, thích ứng để trích xuất tín hiệu tài chính, hoạt động hiệu quả mà không cần sự can thiệp của con người trên các chế độ thị trường đa dạng.

7 Hạn chế

framework của chúng tôi có một số hạn chế đáng kể. Thứ nhất, hiệu quả của hệ thống phụ thuộc vào chất lượng tài liệu đầu vào, có khả năng duy trì các sai lệch cố hữu (tham khảo [7, 1]). Thứ hai, các alpha do LLM tạo ra đôi khi thiếu trực giác tài chính đặc trưng của các nhà phân tích con người, dẫn đến các yếu tố hợp lý về mặt lý thuyết nhưng không khả thi trong thực tế (theo [32]). Thứ ba, phương pháp đánh giá *multi-agent* của chúng tôi giả định các mối quan hệ lịch sử bền vững giữa điều kiện thị trường và hiệu suất alpha—một giả định có thể tỏ ra mong manh trong các giai đoạn thay đổi chế độ thị trường. Cuối cùng, các nỗ lực xác thực của chúng tôi chủ yếu nhắm vào thị trường cổ phiếu, với khả năng áp dụng chéo tài sản đòi hỏi điều tra thực nghiệm bổ sung. Các hướng nghiên cứu trong tương lai nên giải quyết những hạn chế này bằng cách khám phá các kiến trúc Hỗn hợp Chuyên gia (MoE - Mixture of Experts) để cải thiện hiệu quả học tập (theo [22]), các kiến trúc *agent* thích ứng, các phương pháp học chuyển giao (tham khảo [36]), và các triển khai hiệu quả về mặt tính toán.

Tài liệu

- [1] Aditya Ashok, Manimaran Govindarasu, and Venkataramana Ajjarapu. 2018. Online detection of stealthy false data injection attacks in power system state estimation. *IEEE Transactions on Smart Grid*, 9(3):1636–1646.
- [2] Chi Chen, Li Zhao, Jiang Bian, Chunxiao Xing, and Tie-Yan Liu. 2019. Investment behaviors can tell what inside: Exploring stock intrinsic properties for stock trend prediction. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 2376–2384.
- [3] Tianqi Chen and Carlos Guestrin. 2016. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, San Francisco, CA, USA. ACM.

- [4] Yinpeng Chen and et al. 2020. Dynamic relu. In *European Conference on Computer Vision*. Springer International Publishing.
- [5] L. W. Cong, K. Tang, J. Wang, and Y. Zhang. 2021. Alphaportfolio: Direct construction through deep reinforcement learning and interpretable ai.
- [6] Can Cui, Wei Wang, Meihui Zhang, Gang Chen, Zhaojing Luo, and Beng Chin Ooi. 2021. Alphaevolve: A learning framework to discover novel alphas in quantitative investment. In *Proceedings of the 2021 International Conference on Management of Data (SIGMOD '21)*, pages 2208–2216, Virtual Event, China. ACM.
- [7] Chirag Deb, Fan Zhang, Junjing Yang, Siew Eang Lee, and Kwok Wei Shah. 2017. A review on time series forecasting techniques for building energy consumption. *Renewable and Sustainable Energy Reviews*, 74:902–924.
- [8] Yujie Ding, Shuai Jia, Tianyi Ma, Bingcheng Mao, Xiuze Zhou, Liuliu Li, and Dongming Han. 2023. Integrating stock features and global information via large language models for enhanced stock return prediction. *Preprint, arXiv:2310.05627*.
- [9] Thomas H Goodwin. 1998. The information ratio. *Financial Analysts Journal*, 54(4):34–43.
- [10] Sepp Hochreiter and Jürgen Schmidhuber. 1997. Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- [11] Ouyang K, Liu Y, Li S, and et al. 2024. Modal-adaptive knowledge-enhanced graph-based financial prediction from monetary policy conference calls with llm.
- [12] Zura Kakushadze. 2016. 101 formulaic alphas. *Wilmott*, 2016(84):72–81.
- [13] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017*, pages 3146–3154, Long Beach, CA, USA. Neural Information Processing Systems Foundation.
- [14] K. J. Koa, Y. Ma, R. Ng, and T.-S. Chua. 2024. Learning to generate explainable stock predictions using self-reflective large language models. In *Proceedings of the ACM on Web Conference 2024*, pages 4304–4315.
- [15] Li L, Chang T Y, and Wang H. 2023. Multimodal gen-ai for fundamental investment research.
- [16] Jean Lee, Nicholas Stevens, and Soyeon Caren Han. 2025. Large language models in finance (finllms). *Neural Computing and Applications*.
- [17] Jinho Lee, Raehyun Kim, Seok-Won Yi, and Jaewoo Kang. 2020. Maps: *multi-agent* reinforcement learning-based portfolio management system. In *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence, IJCAI-PRICAI-2020*, page 4520–4526. International Joint Conferences on Artificial Intelligence Organization.

- [18] P. Lewis and et al. 2020. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *NeurIPS*, volume 33, pages 9459–9474.
- [19] Weiping Li and Feng Mei. 2020. Asset returns in deep learning methods: An empirical analysis on sse 50 and csi 300. *Research in International Business and Finance*, 54:101291.
- [20] Xiaoming Lin, Ye Chen, Ziyu Li, and Kang He. 2019. Stock alpha mining based on genetic algorithm. *Technical report, Huatai Securities Research Center*.
- [21] Andrew W Lo. 2007. Where do alphas come from?: A new measure of the value of active investment management. *A new measure of the value of active investment management (May 8, 2007)*.
- [22] Saeed Masoudnia and Reza Ebrahimpour. 2014. Mixture of experts: a literature survey. *Artificial Intelligence Review*, 42:275–293.
- [23] T. Nathan Mundhenk, Mikel Landajuela, Ruben Glatt, Daniel M. Faissol, and Brenden K. Petersen. 2021. Symbolic regression via neural-guided genetic programming population seeding. In *9th International Conference on Learning Representations (ICLR)*, Virtual Event, Austria.
- [24] Robert Novy-Marx. 2015. Fundamentally, momentum is fundamental momentum. *Technical Report w20984, NBER*.
- [25] OpenAI. 2023. Gpt-4 technical report.
- [26] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 2017. Proximal policy optimization algorithms. *Preprint, arXiv:1707.06347*.
- [27] William F Sharpe. 1994. The sharpe ratio. *Journal of portfolio management*, 21(1):49–58.
- [28] Thomas Spooner and Rahul Savani. 2020. Robust market making via adversarial reinforcement learning. *Preprint, arXiv:2003.01820*.
- [29] Y. Talebirad and A. Nadiri. 2023. *multi-agent* collaboration: Harnessing the power of intelligent llm *agents*.
- [30] Ziyi Tang, Zechuan Chen, Jiarui Yang, Jiayao Mai, Yongsun Zheng, Keze Wang, Jinrui Chen, and Liang Lin. 2025. Alphaagent: LLM-driven alpha mining with regularized exploration to counteract alpha decay. *Preprint, arXiv:2502.16789*.
- [31] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample. 2023. Llama: Open and efficient foundation language models.
- [32] Suppawong Tuarob, Conrad S. Tucker, Soundar R. T. Kumara, C. Lee Giles, Aaron L. Pincus, David E. Conroy, and Nilam Ram. 2017. How are you feeling: A personalized methodology for predicting mental states from temporally observable physical and behavioral information. *Journal of Biomedical Informatics*, 68:1–19.

- [33] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017*, pages 5998–6008, Long Beach, CA, USA. Neural Information Processing Systems Foundation.
- [34] B. W. and et al. 2023. Bloom: A 176b-parameter open-access multilingual language model.
- [35] H. W. and et al. 2022. Scaling instruction-finetuned language models.
- [36] Liping Wang, Jiawei Li, Lifan Zhao, Zhizhuo Kou, Xiaohan Wang, Xinyi Zhu, Hao Wang, Yanyan Shen, and Lei Chen. 2023. Methods for acquiring and incorporating knowledge into stock price prediction: A survey. *arXiv preprint arXiv:2308.04947*.
- [37] Qineng Wang, Zihao Wang, Ying Su, Hanghang Tong, and Yangqiu Song. 2024. Rethinking the bounds of llm reasoning: Are *multi-agent* discussions the key? *arXiv preprint arXiv:2402.18272*.
- [38] Shijie Wu, Ozan Irsoy, Steven Lu, Vadim Dabravolski, Mark Dredze, Sebastian Gehrmann, Prabhajan Kambadur, David Rosenberg, and Gideon Mann. 2023. Bloomberggpt: A large language model for finance. *Preprint, arXiv:2303.17564*.
- [39] Wentao Xu, Weiqing Liu, Lewen Wang, Yingce Xia, Jiang Bian, Jian Yin, and Tie-Yan Liu. 2021a. Hist: A graph-based framework for stock trend forecasting via mining concept-oriented shared information.
- [40] Wentao Xu, Weiqing Liu, Chang Xu, Jiang Bian, Jian Yin, and Tie-Yan Liu. 2021b. Rest: Relational event-driven stock trend forecasting. In *WWW '21: The Web Conference 2021*, pages 1–10, Virtual Event / Ljubljana, Slovenia. ACM / IW3C2.
- [41] Yumo Xu and Shay B Cohen. 2018. Stock movement prediction from tweets and historical prices. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1970–1979.
- [42] Y. Yang, Y. Tang, and K. Y. Tam. 2023. Investlm: A large language model for investment using financial domain instruction tuning.
- [43] Shuo Yu, Hongyan Xue, Xiang Ao, Feiyang Pan, Jia He, Dandan Tu, and Qing He. 2023a. Generating synergistic formulaic alpha collections via reinforcement learning. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '23)*, pages 5476–5486, New York, NY, USA. Association for Computing Machinery.
- [44] Yangyang Yu and et al. 2024. Finmem: A performance-enhanced llm trading *agent* with layered memory and character design. In *Proceedings of the AAAI Symposium Series*, volume 3.
- [45] Yangyang Yu, Haohang Li, Zhi Chen, Yuechen Jiang, Yang Li, Denghui Zhang, Rong Liu, Jordan W. Suchow, and Khaldoun Khashanah. 2023b. Finmem: A performance-enhanced llm trading *agent* with layered memory and character design. *Preprint, arXiv:2311.13743*.

- [46] Yangyang Yu, Zhiyuan Yao, Haohang Li, Zhiyang Deng, Yupeng Cao, Zhi Chen, Jordan W. Suchow, Rong Liu, Zhenyu Cui, Zhaozhuo Xu, Denghui Zhang, Koduvayur Subbalakshmi, Guojun Xiong, Yueru He, Jimin Huang, Dong Li, and Qianqian Xie. 2024. Fincon: A synthesized llm *multi-agent* system with conceptual verbal reinforcement for enhanced financial decision making. *Preprint, arXiv:2407.06567*.
- [47] Chong Zhang, Xinyi Liu, Zhongmou Zhang, Mingyu Jin, Lingyao Li, Zhenting Wang, Wenyue Hua, Dong Shu, Suiyuan Zhu, Xiaobo Jin, Sujian Li, Mengnan Du, and Yongfeng Zhang. 2024a. When ai meets finance (stockagent): Large language model-based stock trading in simulated real-world environments. *Preprint, arXiv:2407.18957*.
- [48] Feng Zhang, Ruite Guo, and Honggao Cao. 2020. Information coefficient as a performance measure of stock selection models.
- [49] W. Zhang, L. Zhao, H. Xia, and et al. 2024b. A multi-modal foundation *agent* for financial trading: Tool-augmented, diversified, and generalist. *Technical report*.
- [50] H. Zhao, Z. Liu, Z. Wu, and et al. 2024. Revolutionizing finance with llms: An overview of applications and insights.
- [51] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong, and et al. 2023. A survey of large language models.


A Phụ lục

A.1 Mẫu seed alpha

Biểu diễn seed alpha được mô tả trong Hình 4 minh họa một cấu trúc cơ bản trong tài chính định lượng để tạo tín hiệu giao dịch. Hình này trình bày một hình ảnh toàn diện về công thức Bộ dao động Giá đã loại bỏ Xu hướng (DPO - Detrended Price Oscillator), so sánh giá đóng cửa hiện tại với trung bình động đơn giản (SMA) trễ của giá đóng cửa. Phần (A) của hình cho thấy công thức toán học của seed alpha, được biểu thị bằng $CLOSE - DELAY(SMA(CLOSE, 14), 7)$, nắm bắt động lượng giá bằng cách đo lường độ lệch so với xu hướng lịch sử. Phần (B) chuyển đổi công thức này thành một cây biểu thức tương đương, thể hiện mối quan hệ phân cấp giữa các toán tử và toán hạng, tạo điều kiện thuận lợi cho việc triển khai và phân tích thuật toán. Phần (C) cung cấp một minh họa thực tế thông qua tính toán từng bước của công thức alpha này trên một chuỗi thời gian mẫu, cho thấy tín hiệu phát triển như thế nào qua nhiều ngày giao dịch. Biểu diễn này minh họa cách các chỉ báo tài chính phức tạp có thể được phân tách, hình thức hóa và áp dụng một cách có hệ thống vào dữ liệu thị trường cho các chiến lược giao dịch định lượng.

A.2 Danh sách tài liệu seed alpha cho GPT

Bảng 11 trình bày một cái nhìn tổng quan toàn diện về các nghiên cứu tiên tiến liên quan đến việc phát triển Nhà máy seed alpha (SAF) trong tài chính định lượng. Các tài liệu này thể hiện sự hội tụ của các phương pháp tài chính truyền thống với các kỹ thuật tính toán tiên tiến. Điều đặc biệt quan trọng là "101 Yếu tố Alpha Công thức" của [12], cung cấp một kho lưu trữ cơ bản các tín hiệu giao dịch có thể được phân loại theo



Hình 4: Biểu diễn seed alpha: (A) Một ví dụ về công thức seed alpha. (B) Cây biểu thức tương đương của nó. (C) Tính toán từng bước của seed alpha này trên một chuỗi thời gian ví dụ.

các yếu tố tài chính truyền thống. Công trình của Lopez de Prado về "Đầu tư Yếu tố Nguyên nhân" giới thiệu tính chặt chẽ khoa học vào việc phân loại yếu tố, đảm bảo tính độc lập giữa các danh mục alpha. Sự tích hợp của trí tuệ nhân tạo được thể hiện rõ trong nhiều nghiên cứu, bao gồm "Alpha-GPT" và "FinGPT", tận dụng LLMs để tạo alpha. Các phương pháp xây dựng danh mục đầu tư được giải quyết thông qua các phương pháp học tăng cường trong "AlphaPortfolio" (tham khảo [5]) và "Học tăng cường sâu dựa trên đồ thị động". Các chiến lược nâng cao hiệu suất được khám phá trong "Làm chủ Thị trường Chứng khoán với Hỗn hợp Hiệu quả của các Chuyên gia Giao dịch Đa dạng," trong khi phân tích sự phụ thuộc của thị trường được đề cập trong "Sự phụ thuộc Ngụ ý Phi mô hình và Mặt cắt Ngang của Lợi nhuận." Bộ sưu tập tài liệu này cung cấp cho các nhà nghiên cứu định lượng framework lý thuyết và các công cụ phương pháp luận cần thiết để xây dựng một Nhà máy seed alpha (Seed Alpha Factory) tạo ra, phân loại và triển khai các tín hiệu giao dịch một cách có hệ thống trên các danh mục tài chính độc lập, cân bằng lý thuyết tài chính truyền thống với những tiến bộ tính toán đương đại.

Mẫu prompt được sử dụng: "Tóm tắt thông tin tài liệu để giúp các nhà nghiên cứu định lượng xây dựng Nhà máy seed alpha theo các danh mục tài chính truyền thống, đảm bảo rằng mỗi danh mục seed alpha là độc lập."

A.3 Tạo Nhà máy seed alpha

Bảng 12 trình bày các tín hiệu giao dịch định lượng được tổ chức thành chín danh mục: Động lượng, Đảo chiều Trung bình, Biến động, Cơ bản, Thanh khoản, Chất lượng, Tăng trưởng, Kỹ thuật và các chỉ số Kinh tế Vĩ mô. Mỗi danh mục nhắm mục tiêu các hiện tượng thị trường riêng biệt với các triển khai toán học cụ thể. Các yếu tố động lượng xác định các xu hướng bền vững, tín hiệu đảo chiều trung bình phát hiện các phản ứng thái quá của thị trường, các chỉ số biến động định lượng sự phân tán giá và các yếu tố cơ bản đánh giá định giá công ty. framework cũng bao gồm các thước đo thanh khoản của hoạt động giao dịch, các chỉ số chất lượng về hiệu quả hoạt động, các chỉ số tăng trưởng của việc mở rộng tài chính, các chỉ báo kỹ thuật bắt nguồn từ các mô hình giá-khối lượng và các tín hiệu kinh tế vĩ mô phản ánh các điều kiện kinh tế rộng hơn. Các công thức toán học được cung cấp cho phép các nhà nghiên cứu triển khai các yếu tố alpha đa dạng, không tương quan cho các chiến lược giao dịch định lượng mạnh mẽ.

Bảng 11: Danh sách Tài liệu seed alpha cho GPT

Tên tài liệu	Tác giả
Financial Time Series Prediction Using Mixture of Experts	M. Serdar Yumlu, Fikret S. Gorgen, and Nesrin Okay
Model-Free Implied Dependence and the Cross-Section of Returns	Koen Inghelbrecht, Gertjan Verdict, Daniël Linders, and Yong Xie
Dynamic Graph-based Deep Reinforcement Learning with Long and Short-term Relation Modeling for Portfolio Optimization	Pengqian Yu, Joon Sern Lee, Ilya Kulyatin, Zekun Shi, Sakyasingha Dasgupta
Can Large Language Models Beat Wall Street? Unveiling the Potential of AI in Stock Selection	Georgios Fatouros, Konstantinos Metaxas, John Soldatos, Dimosthenis Kyriazis
Mastering Stock Markets with Efficient Mixture of Diversified Trading Experts	Shuo Sun, Xinrun Wang, Wanqi Xue, Xiaoxuan Lou, and Bo An
101 Formulaic Alphas	Zura Kakushadze ([12])
A Multimodal Foundation Agent for Financial Trading: Tool-Augmented, Diversified, and Generalist	Wentao Zhang, Lingxuan Zhao, Haochong Xia, Shuo Sun, Jiaze Sun, Molei Qin, Xinyi Li, Yuqing Zhao, Yilei Zhao, Xinyu Cai, Longtao Zheng, Xinrun Wang, Bo An ([49])
Causal Factor Investing: Can Factor Investing Become Scientific?	Marcos Lopez de Prado
Alpha-GPT: Human-AI Interactive Alpha Mining for Quantitative Investment	Saizhuo Wang, Hang Yuan, Leon Zhou, Lionel M. Ni, Heung-Yeung Shum, Jian Guo
AlphaPortfolio: Direct Construction Through Deep Reinforcement Learning and Interpretable AI	Lin William Cong, Ke Tang, Jingyuan Wang, Yang Zhang ([5])
FinGPT: Open-Source Financial Large Language Models	Hongyang (Bruce) Yang, Xiao-Yang Liu, Christina Dan Wang ([42])

Bảng 12: Danh sách các Yếu tố seed alpha

Loại	Tên	Công thức
Động lượng	Động lượng Giá	$(CLOSE - DELAY(CLOSE, 14))$
	Động lượng Khối lượng	$(VOLUME - DELAY(VOLUME, 14))$
	Động lượng RSI	$(RSI - DELAY(RSI, 14))$
	Tỷ lệ Thay đổi (ROC)	$((CLOSE / DELAY(CLOSE, 14)) - 1)$
	Động lượng MACD	$(MACD - DELAY(MACD, 14))$
	Bộ dao động Động lượng	$((CLOSE - DELAY(CLOSE, 14)) / DELAY(CLOSE, 14))$
	Bộ dao động Động lượng Chande (CMO)	$(SUM(IF(CLOSE - DELAY(CLOSE, 1) > 0, CLOSE - DELAY(CLOSE, 1), 0), 14) - SUM(IF(CLOSE - DELAY(CLOSE, 1) < 0, DELAY(CLOSE, 1) - CLOSE, 0), 14)) / (SUM(IF(CLOSE - DELAY(CLOSE, 1) > 0, CLOSE - DELAY(CLOSE, 1), 0), 14) + SUM(IF(CLOSE - DELAY(CLOSE, 1) < 0, DELAY(CLOSE, 1) - CLOSE, 0), 14))) * 100$
	Chỉ số Động lượng Stochastic (SMI)	$((CLOSE - MIN(LOW, 14)) - (MAX(HIGH, 14) - CLOSE)) / (MAX(HIGH, 14) - MIN(LOW, 14))$
	Động lượng ATR	$(ATR - DELAY(ATR, 14))$
	Bộ dao động Giá đã loại bỏ Xu hướng (DPO)	$(CLOSE - DELAY(SMA(CLOSE, 14), 7))$

Tiếp theo từ bảng trên

Loại	Tên	Công thức
	Động lượng Chỉ số Định hướng Trung bình (ADX)	$(ADX - \text{DELAY}(ADX, 14))$
Đảo chiều Trung bình	Đảo chiều Trung bình	$(\text{MEAN}(\text{CLOSE}, 20) - \text{CLOSE})$
	Đảo chiều Trung bình Z-Score	$(\text{CLOSE} - \text{MEAN}(\text{CLOSE}, 20)) / \text{STD}(\text{CLOSE}, 20)$
	Dải Bollinger	$(\text{CLOSE} - \text{LOWER_BAND}) / (\text{UPPER_BAND} - \text{LOWER_BAND})$
	Kênh Keltner	$(\text{CLOSE} - \text{LOWER_CHANNEL}) / (\text{UPPER_CHANNEL} - \text{LOWER_CHANNEL})$
	Đảo chiều Trung bình Động	$(\text{SMA}(\text{CLOSE}, 20) - \text{CLOSE})$
	Đảo chiều Trung bình Động Hàm mũ (EMA)	$(\text{EMA}(\text{CLOSE}, 20) - \text{CLOSE})$
	Khoảng cách từ Đỉnh	$(\text{MAX}(\text{HIGH}, 20) - \text{CLOSE})$
	Khoảng cách từ Đáy	$(\text{CLOSE} - \text{MIN}(\text{LOW}, 20))$
	Đảo chiều Chỉ số Sức mạnh Tương đối (RSI)	$(100 - \text{RSI})$
	Phần trăm B	$((\text{CLOSE} - \text{LOWER_BAND}) / (\text{UPPER_BAND} - \text{LOWER_BAND})) * 100$
Biến động	Độ lệch Chuẩn	$\text{STD}(\text{CLOSE}, 20)$
	Khoảng dao động Thực Trung bình (ATR)	$\text{ATR}(14)$
	Độ rộng Dải Bollinger	$(\text{UPPER_BAND} - \text{LOWER_BAND}) / \text{SMA}(\text{CLOSE}, 20)$
	Biến động Lịch sử	$\text{STD}(\text{RETURNS}, 20) * \text{SQRT}(252)$
	Tỷ lệ Biến động	$\text{STD}(\text{CLOSE}, 10) / \text{STD}(\text{CLOSE}, 50)$
	Biến động Chaikin	$(\text{EMA}(\text{HIGH} - \text{LOW}, 10) / \text{DELAY}(\text{EMA}(\text{HIGH} - \text{LOW}, 10), 10)) - 1$
	Biến động Garman-Klass	$\text{SQRT}(0.5 * \text{LOG}(\text{HIGH} / \text{LOW})^2 - (2 * \text{LOG}(2) - 1) * \text{LOG}(\text{CLOSE} / \text{OPEN})^2)$
	Biến động Parkinson	$\text{SQRT}((1 / (4 * N * \text{LOG}(2))) * \text{SUM}(\text{LOG}(\text{HIGH} / \text{LOW})^2, 20))$
	Biến động Yang-Zhang	$\text{SQRT}(\text{VAR}(\text{LOG}(\text{CLOSE} / \text{OPEN})) + 0.5 * \text{VAR}(\text{LOG}(\text{HIGH} / \text{OPEN}) - \text{LOG}(\text{LOW} / \text{OPEN})) + 0.25 * \text{VAR}(\text{LOG}(\text{CLOSE} / \text{DELAY}(\text{OPEN}, 1))))$
	Chỉ số Ulcer	$\text{SQRT}(\text{MEAN}(\text{DRAWDOWN}^2, 14))$
Cơ bản	Tỷ lệ Giá trên Thu nhập (P/E)	$(\text{CLOSE} / \text{EPS})$

Tiếp theo từ bảng trên

Loại	Tên	Công thức
	Tỷ lệ Giá trên Giá trị Sổ sách (P/B) Lợi suất Cổ tức Lợi suất Thu nhập Tỷ lệ Doanh thu trên Giá Lợi suất Dòng tiền	(CLOSE/BOOK_VALUE) (DIVIDENDS / CLOSE) (EPS / CLOSE) (SALES / CLOSE) (OPERATING_CASH_FLOW / CLOSE)
Thanh khoản	Khối lượng Giao dịch Khối lượng Giao dịch Trung bình Tỷ lệ Thay đổi Khối lượng (VROC) Khối lượng Cân bằng (OBV) Tỷ lệ Thanh khoản Tỷ lệ Vòng quay Tỷ lệ Thanh khoản kém Amihud Chênh lệch Cao-Thấp (Thanh khoản) Khối lượng Đô la (Thanh khoản)	VOLUME MEAN(VOLUME, 20) (VOLUME - DELAY(VOLUME, 14)) / DELAY(VOLUME, 14) SUM(VOLUME * SIGN(CLOSE - DELAY(CLOSE, 1))) VOLUME/MARKET_CAP VOLUME / SHARES_OUTSTANDING ABS(RETURN) / VOLUME (HIGH - LOW) / CLOSE VOLUME * CLOSE
Chất lượng	Tỷ lệ Nợ trên Vốn chủ sở hữu (Chất lượng) Lợi nhuận trên Vốn chủ sở hữu (ROE) Lợi nhuận trên Tài sản (ROA) Biên Lợi nhuận Gộp (Chất lượng) Tỷ lệ Giá trên Doanh thu (P/S) Tỷ lệ Giá trên Dòng tiền (P/CF) Tỷ lệ Giá trị Sổ sách trên Thị trường (B/M) Giá trị Doanh nghiệp trên EBITDA (EV/EBITDA) Chênh lệch Mua-Bán Biên Lợi nhuận Hoạt động Biên Lợi nhuận Ròng Độ ổn định Thu nhập Tỷ lệ Trang trải Lãi vay Chu kỳ Chuyển đổi Tiền mặt	(TOTAL_DEBT / TOTAL_EQUITY) (NET_INCOME/EQUITY) (NET_INCOME / TOTAL_ASSETS) (GROSS_PROFIT / REVENUE) (CLOSE/SALES) (CLOSE/OPERATING_CASH_FLOW) (BOOK_VALUE / CLOSE) (ENTERPRISE_VALUE / EBITDA) (ASK_PRICE - BID_PRICE) / MID_PRICE (OPERATING_INCOME / REVENUE) (NET_INCOME / REVENUE) STD(EPS, 5) / MEAN(EPS, 5) (EBIT/INTEREST_EXPENSE) (DIO + DSO - DPO)

Tiếp theo từ bảng trên

Loại	Tên	Công thức
	Vòng quay Tài sản	(REVENUE / TOTAL_ASSETS)
Tăng trưởng	Tốc độ Tăng trưởng Thu nhập	(EPS / DELAY(EPS, 1) - 1)
	Tốc độ Tăng trưởng Doanh thu	(REVENUE / DELAY(REVENUE, 1) - 1)
	Tốc độ Tăng trưởng EBITDA	(EBITDA / DELAY(EBITDA, 1) - 1)
	Tốc độ Tăng trưởng Dòng tiền	(CASH_FLOW / DELAY(CASH_FLOW, 1) - 1)
	Tốc độ Tăng trưởng Cổ tức	(DIVIDENDS / DELAY(DIVIDENDS, 1) - 1)
	Tốc độ Tăng trưởng Giá trị Sổ sách	(BOOK_VALUE / DELAY(BOOK_VALUE, 1) - 1)
	Tốc độ Tăng trưởng Doanh số	(SALES / DELAY(SALES, 1) - 1)
	Tốc độ Tăng trưởng Tài sản	(ASSETS/DELAY(ASSETS, 1) - 1)
	Tốc độ Tăng trưởng Vốn chủ sở hữu	(EQUITY / DELAY(EQUITY, 1) - 1)
	Tốc độ Tăng trưởng Lợi nhuận Giữ lại	(RETAINED_EARNINGS / DELAY(RETAINED_EARNINGS, 1) - 1)
Kỹ thuật	Trung bình Động (MA)	SMA(CLOSE, 20)
	Trung bình Động Hàm mũ (EMA)	EMA(CLOSE, 20)
	Chỉ số Sức mạnh Tương đối (RSI)	RSI(14)
	Hội tụ Phân kỳ Trung bình Động (MACD)	(EMA(CLOSE, 12) - EMA(CLOSE, 26))
	Dải Bollinger (Kỹ thuật)	UPPER_BAND - LOWER_BAND
	Bộ dao động Stochastic	((CLOSE - MIN(LOW, 14)) / (MAX(HIGH, 14) - MIN(LOW, 14))) * 100
	Khoảng dao động Thực Trung bình (ATR Kỹ thuật)	ATR(14)
	Chỉ số Kênh Hàng hóa (CCI)	(TYPICAL_PRICE - SMA(TYPICAL_PRICE, 20)) / (0.015 * MEAN_DEV(TYPICAL_PRICE, 20))
	Williams %R	((MAX(HIGH, 14) - CLOSE) / (MAX(HIGH, 14) - MIN(LOW, 14))) * -100
Kinh tế Vĩ mô	Tốc độ Tăng trưởng GDP	GDP - DELAY(GDP, n)
	Tỷ lệ Lạm phát	CPI - DELAY(CPI, n)

Tiếp theo từ bảng trên

Loại	Tên	Công thức
	Tỷ lệ Thất nghiệp	UNEMPLOYMENT_RATE -
	Lãi suất	DELAY(UNEMPLOYMENT_RATE, n)
	Chỉ số Sản xuất Công nghiệp	INTEREST_RATE - DELAY(INTEREST_RATE, n)
	Tăng trưởng Doanh số Bán lẻ	IPI - DELAY(IPI, n)
	Tăng trưởng Số lượng Nhà ở Khởi công	RETAIL_SALES - DELAY(RETAIL_SALES, n)
	Chỉ số Niềm tin Người tiêu dùng (CCI Vĩ mô)	HOUSING_STARTS - DELAY(HOUSING_STARTS, n)
	Cán cân Thương mại	CCI - DELAY(CCI, n)
	Dự trữ Ngoại hối	EXPORTS - IMPORTS
		FX_RESERVES - DELAY(FX_RESERVES, n)

A.4 Các loại dữ liệu đa phương thức

Bảng 13 trình bày một phân loại các loại dữ liệu đa phương thức cần thiết cho nghiên cứu tài chính định lượng toàn diện. Phân loại này bao gồm năm loại: dữ liệu văn bản (báo cáo tài chính, bài báo, diễn ngôn truyền thông xã hội), dữ liệu số (chuỗi giá lịch sử, lợi nhuận, các chỉ số biến động), dữ liệu trực quan (biểu đồ và các mô hình phân tích kỹ thuật), dữ liệu âm thanh (chương trình phát thanh tài chính và bình luận thị trường), và dữ liệu video (các kênh tin tức tài chính chuyên biệt). framework đa phương thức này cho phép các nhà nghiên cứu phát triển các mô hình dự đoán mạnh mẽ hơn bằng cách tích hợp các kênh thông tin bổ sung, có khả năng xác định các yếu tố kém hiệu quả của thị trường mà không thể phát hiện được khi phân tích các loại dữ liệu riêng lẻ. Bằng cách tổng hợp các định dạng thông tin đa dạng, các nhà phân tích định lượng có thể thu được những hiểu biết đa chiều về động lực thị trường, nâng cao cả chiều sâu phân tích và khả năng dự đoán trong các ứng dụng mô hình hóa tài chính.

A.5 Lựa chọn Alpha dựa trên danh mục

Thuật toán 1 mô tả một phương pháp luận có hệ thống để lựa chọn alpha trong các chiến lược đầu tư định lượng, sử dụng một phương pháp dựa trên danh mục để đảm bảo sự đa dạng hóa trên nhiều yếu tố tài chính. Quy trình hoạt động trên một tập hợp các danh mục alpha có cấu trúc C , mỗi danh mục đại diện cho các hiện tượng thị trường riêng biệt như động lượng, đảo chiều trung bình hoặc biến động. Đối với mỗi danh mục, thuật toán xác định các yếu tố alpha vượt trội thông qua hàm **SelectBestAlphas**, hàm này được cho là đánh giá các chỉ số hiệu suất lịch sử. Sự đổi mới nằm ở hệ thống đánh giá *agent* kép tiếp theo: **RiskPreferenceAgent** đánh giá các đặc điểm rủi ro của mỗi alpha, trong khi **ConfidenceScoreAgent** đánh giá tính mạnh mẽ thống kê của hiệu suất lịch sử của nó. Các đánh giá bổ sung này được tổng hợp bằng cách sử dụng các tham số trọng số w_r và w_c để tính toán Điểm Cuối cùng toàn diện. Chỉ những alpha vượt qua ngưỡng tin cậy được xác định trước X mới được đưa vào tập hợp lựa chọn cuối cùng A . Phương pháp có phương pháp này đảm bảo rằng danh mục alpha kết quả thể hiện cả sự đa dạng

Bảng 13: Các loại dữ liệu đa phương thức

Loại Dữ liệu	Mô tả	Ví dụ
Dữ liệu Văn bản	Báo cáo tài chính, bài báo khoa học, tin tức và các tài liệu văn bản khác.	Phân tích tâm lý diễn đàn giao dịch, dự đoán cổ phiếu, công bố của công ty, báo cáo tài chính, Sina Finance
Dữ liệu Số	Dữ liệu thị trường chứng khoán lịch sử, các chỉ số tài chính, và các chỉ số hiệu suất.	Lợi nhuận, lợi nhuận log, lợi nhuận hàng năm, biến động
Dữ liệu Trực quan	Biểu đồ, đồ thị, và các biểu diễn trực quan khác của dữ liệu tài chính.	Biểu đồ Kline, biểu đồ giao dịch
Dữ liệu Âm thanh	Chương trình phát thanh tài chính.	Radio tin tức tài chính buổi sáng, radio đánh giá cổ phiếu, radio thảo luận thị trường
Dữ liệu Video	Kênh tin tức tài chính.	Kênh Thông tin Chứng khoán CCTV, Bản tin Thời sự CCTV (tin tức ảnh hưởng đến thị trường chứng khoán Trung Quốc)

hóa danh mục và chất lượng tín hiệu riêng lẻ, có khả năng nâng cao lợi nhuận điều chỉnh theo rủi ro trong khi giảm thiểu rủi ro đối với các chế độ thị trường cụ thể hoặc sự suy giảm yếu tố.

Input: các danh mục $C = \{C_1, \dots, C_m\}$, mỗi C_i chứa một tập hợp các Alpha, ngưỡng tin cậy X

Output: Các Alpha đã chọn A

Khởi tạo các Alpha đã chọn $A = \{\}$; **foreach** danh mục $C_i \in C$ **do**

$A_i = \text{SelectBestAlphas}(C_i)$; **foreach** mỗi $a \in A_i$ **do**

 Risk Score $\leftarrow \text{RiskPreferenceAgent}(a)$; Confidence Score

$\leftarrow \text{ConfidenceScoreAgent}(a)$; Final Score

$= w_r \cdot \text{Risk Score} + w_c \cdot \text{Confidence Score}$; **if** Final Score $> X$ **then**

$A = A \cup \{a\}$;

end

end

end

return A ;

Algorithm 1: Lựa chọn Alpha Dựa trên Danh mục

A.6 Xây dựng chiến lược Alpha động

Thuật toán 2 trình bày chi tiết framework tổng thể của chúng tôi.

Input: Dữ liệu tài chính đa phương thức D , điều kiện thị trường $M^{(t)}$, cổ phiếu S , ngưỡng tin cậy τ

Output: Chiến lược alpha tối ưu $\alpha^{(t)}$

/ Giai đoạn 1: SAF */*

Khởi tạo Nhà máy seed alpha trống $F \leftarrow \emptyset$;

foreach tài liệu $d \in D$ **do**

 nội dung đã lọc $\leftarrow \text{LLM.Filter}(d)$;

 danh mục $\leftarrow \text{LLM.Categorize}(\text{nội dung đã lọc})$;

foreach danh mục $c \in \text{danh mục}$ **do**

 alphas_hạt_giống $\leftarrow \text{LLM.GenerateAlphas}(c)$;

$F_c \leftarrow F_c \cup \text{alphas_hạt_giống}$;

end

end

/ Giai đoạn 2: Đánh giá multi-agent */*

Khởi tạo các alpha đã chọn $A \leftarrow \emptyset$;

foreach danh mục $c \in F$ **do**

foreach mỗi alpha $a_{ij} \in F_c$ **do**

$\theta_{ij} \leftarrow \text{ConfidenceScoreAgent}(a_{ij}, M^{(t)})$ **[r]Đánh giá thống kê*

$\rho_{ij} \leftarrow \text{RiskPreferenceAgent}(a_{ij}, M^{(t)})$ **[r]Đánh giá rủi ro*

$\text{score}_{ij} \leftarrow w_c \cdot \theta_{ij} + w_r \cdot \rho_{ij}$ **[r]Điểm kết hợp* **if** $\text{score}_{ij} > \tau$ **then**

$A_c \leftarrow A_c \cup \{a_{ij}\}$;

end

end

if $A_c \neq \emptyset$ **then**

$a_c^* \leftarrow \arg \max_{a_{ij} \in A_c} \text{score}_{ij}$ **[r]Chọn alpha tốt nhất trong danh mục*

$A \leftarrow A \cup \{a_c^*\}$;

end

end

/ Giai đoạn 3: Tối ưu hóa Trọng số */*

Khởi tạo MLP với kiến trúc $\{|A|, 10, 1\}$ **[r]Lớp đầu vào, ẩn, đầu ra*

$X_{\text{train}} \leftarrow \text{ComputeHistoricalAlphas}(A, S, t_{\text{start}}, t_{\text{end}})$;

$y_{\text{train}} \leftarrow \text{FutureReturns}(S, t_{\text{start}} + 1, t_{\text{end}} + 1)$;

$w \leftarrow \text{TrainMLP}(X_{\text{train}}, y_{\text{train}})$ **[r]Học trọng số tối ưu* **foreach** mỗi cổ phiếu

$S_i \in S$ **do**

$\alpha_i^{(t)} \leftarrow \sum_{j=1}^{|A|} w_j \cdot a_{ij}^{(t)}$ **[r]Tính alpha tổng hợp*

end

return $\alpha^{(t)} = \{\alpha_1^{(t)}, \alpha_2^{(t)}, \dots, \alpha_N^{(t)}\}$ **[r]Chiến lược alpha cuối cùng*

Algorithm 2: Thuật toán Tổng thể Framework

A.7 Mẫu prompt để lựa chọn seed alpha

Tập huấn luyện bao gồm:

- **Báo cáo Tài chính:** 6 quý (từ tháng 1 năm 2021 đến tháng 6 năm 2022) cho 50 công ty niêm yết trên SSE 50.
- **Dữ liệu Phân tích Yếu tố:** 37 yếu tố (từ tháng 1 năm 2021 đến tháng 6 năm 2022) được chia thành các nhóm: Động lượng, Đảo chiều Trung bình, Biến động,

Cơ bản, Chất lượng, Tăng trưởng, Kỹ thuật, Kinh tế Vĩ mô. Chỉ số được sử dụng là IC.

Mục tiêu: Tìm hiểu mối quan hệ giữa hiệu suất của các báo cáo tài chính trong bốn quý đầu từ năm 2022 đến năm 2023 và dữ liệu phân tích yếu tố (IC) cho mỗi yếu tố trong số 37 yếu tố trong quý cuối cùng của năm 2022.

Khi được cung cấp tập kiểm tra (hiệu suất của bốn quý đầu năm 2023):

- Chọn các yếu tố sẽ hoạt động tốt nhất trong quý cuối cùng của SSE 50.
- Cung cấp điểm tin cậy và sở thích rủi ro cho lựa chọn của bạn cho mỗi yếu tố Alpha đã chọn.

Tiêu chí Lựa chọn:

- Nếu không tìm thấy mối quan hệ nào giữa báo cáo tài chính và IC, hãy chọn yếu tố Alpha có giá trị IC cao nhất trong mỗi nhóm.
- Để xác minh sự khác biệt về thông tin thị trường, nếu không tìm thấy mối quan hệ nào giữa báo cáo tài chính và IR (Tỷ lệ Thông tin), hãy chọn yếu tố Alpha có giá trị IR cao nhất.


A.8 Phương pháp xây dựng danh mục đầu tư

Phương pháp đầu tư của chúng tôi triển khai việc tái cấu trúc danh mục hàng ngày bằng cách sử dụng một framework lựa chọn top-k/bỏ-n. Tại mỗi phiên giao dịch, chúng tôi xếp hạng tất cả các chứng khoán theo giá trị alpha của chúng—các chỉ báo định lượng về lợi nhuận vượt trội dự kiến—và chọn k cổ phiếu hàng đầu để đưa vào danh mục. Phương pháp này nhằm mục tiêu các chứng khoán có tín hiệu mạnh nhất, có khả năng khai thác sự kém hiệu quả của thị trường trong ngắn hạn. Chúng tôi sử dụng một sơ đồ trọng số bằng nhau trên các chứng khoán đã chọn, phân bổ vốn đồng đều giữa các ứng viên hàng đầu, điều này mang lại lợi ích đa dạng hóa và phù hợp với quan điểm của chúng tôi rằng tín hiệu alpha chủ yếu cung cấp các chỉ dẫn hướng chứ không phải dự báo lợi nhuận chính xác.


Để tối ưu hóa chi phí giao dịch và hiệu quả hoạt động, chúng tôi giới hạn vòng quay danh mục ở mức tối đa n chứng khoán mỗi ngày giao dịch. Hạn chế này cân bằng việc duy trì sự phù hợp với các tín hiệu alpha hiện tại trong khi giảm thiểu chi phí ma sát giao dịch. Đối với thử nghiệm của chúng tôi trong Mục 4.D, chúng tôi đặt $k = 13$ và $n = 5$ dựa trên thử nghiệm backtesting rộng rãi. Cấu hình này thiết lập một sự tập trung danh mục cân bằng giữa đa dạng hóa và sự suy giảm tín hiệu, đồng thời giới hạn vòng quay hàng ngày ở mức xấp xỉ 38%—một mức độ cho thấy các đặc điểm thuận lợi trong mô hình hóa chi phí giao dịch của chúng tôi và đại diện cho sự đánh đổi hiệu quả giữa việc sử dụng tín hiệu và chi phí triển khai.

A.9 Kết quả Backtest nghiên cứu tình huống


Các hình từ 5 đến 10 trình bày kết quả backtest chi tiết cho các giai đoạn và thị trường khác nhau được thảo luận trong Mục 4.E.




Hình 5: Backtest tháng 1 - tháng 6 năm 2021 trên CSI300




Hình 6: Backtest tháng 1 - tháng 6 năm 2022 trên CSI300




Hình 7: Backtest tháng 1 - tháng 6 năm 2023 trên CSI300



Hình 8: Backtest tháng 1 - tháng 6 năm 2021 trên SP500



Hình 9: Backtest tháng 1 - tháng 6 năm 2022 trên SP500



Hình 10: Backtest tháng 1 - tháng 6 năm 2023 trên SP500