

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ
VIỆN TRÍ TUỆ NHÂN TẠO



BÁO CÁO MÔN HỌC
SEMINAR KHOA HỌC

TỰ ĐỘNG HÓA TÌM KIẾM
CHIẾN LƯỢC ĐẦU TƯ ĐỊNH
LƯỢNG BẰNG MÔ HÌNH NGÔN
NGŨ LỚN

Giảng viên hướng dẫn: TS. Trần Hồng Việt

Nhóm thực hiện: Nhóm 4 - Morning

Sinh viên thực hiện:

Hoàng Văn Dương

Nguyễn Thế Cường

Nguyễn Gia Huy

Dựa trên công trình của:

Zhizhuo Kou¹, Holam Yu, Junyu Luo, Jingshu Peng¹, Xujia Li¹
Chengzhong Liu, Juntao Dai³, Lei Chen^{1,2}, Sirui Han¹, Yike Guo¹

¹ĐH Khoa học và Công nghệ Hồng Kông, Hồng Kông SAR, Trung Quốc

²ĐH Khoa học và Công nghệ Hồng Kông (Quảng Châu), Trung Quốc

³Đại học Bắc Kinh, Trung Quốc

Hà Nội, tháng 5 năm 2025

Mục lục

Danh mục bảng	ii
Danh mục hình	iii
Danh mục Viết tắt	iv
Tóm tắt	v
1 Mở đầu	1
1.1 Bối cảnh nghiên cứu	1
1.2 Mục tiêu và phạm vi nghiên cứu	1
1.3 Hướng nghiên cứu chính và những đóng góp	2
1.4 Cấu trúc báo cáo	2
2 Cơ sở lý thuyết	3
2.1 Biểu diễn yếu tố Alpha	3
2.2 Khai thác và Lựa chọn Alpha	4
2.3 Tối ưu hóa chiến lược	4
3 Phương pháp	5
3.1 Tổng quan về framework	5
3.2 Tạo seed alpha dựa trên LLM	5
3.3 Đánh giá <i>multi-agent</i> đa phương thức	5
3.4 Tối ưu hóa trọng số	6
4 Thực nghiệm	6
4.1 Dữ liệu	6
4.2 Thiết lập thí nghiệm	7
4.3 Kết quả và Phân tích	7
4.3.1 Trích xuất kiến thức đa phương thức và khám phá Alpha thích ứng	7
4.3.2 Hiệu suất so với các Alpha factor truyền thống	7
4.3.3 Đánh giá hiệu suất của Framework Alpha tích hợp thông qua việc so sánh với tham chiếu chuẩn	8
4.3.4 Sức mạnh của Framework qua các giai đoạn	10
4.3.5 Nghiên cứu Ablation Study	10
4.3.6 Nghiên cứu độ nhạy	11
5 Kết luận	12
5.1 Tổng kết	12
5.2 Hạn chế	12
5.3 Hướng phát triển	13
Tài liệu tham khảo	14

Danh sách bảng

1	Tóm tắt Tập dữ liệu Thử nghiệm	7
2	Hệ số Thông tin (Information Coefficient) (IC) Comparison of mean & selected	7
3	Kiểm tra Kết hợp 12 Alpha trên Shanghai Stock Exchange (Sàn giao dịch Chứng khoán Thượng Hải) (SSE)50 năm 2023	9
4	So sánh Hiệu suất của các Chiến lược Giao dịch	9
5	Các giai đoạn Huấn luyện, Xác thực và Thử nghiệm cho China Securities Index (Chỉ số Chứng khoán Trung Quốc) (CSI)300 và Standard Poor's (SP)500	10
6	Kết quả Hiệu suất Backtest qua các Cửa sổ Thời gian Khác nhau	10
7	Kết quả Nghiên cứu Loại bỏ Thành phần: Tác động của các Thành phần <i>agent</i> lên các Chỉ số Hiệu suất	11
8	Hiệu suất qua các Chế độ Thị trường (IC Ngoài mẫu)	11
9	Độ nhảy với Cấu hình Trọng số <i>agent</i>	12
10	Độ nhảy với các Siêu tham số Mạng Nơ-ron	12

Danh sách hình vẽ

1	Tổng quan về quy trình tạo chiến lược	5
2	Alpha Được chọn Phụ thuộc vào Bối cảnh Khác nhau (Kiến trúc Prompt để lựa chọn Alpha thích ứng)	8
3	Kết quả Backtest Lợi nhuận Tích lũy trên SSE50. Đường theo dõi giá trị ròng của các phương pháp khác nhau	9

Danh mục Viết tắt

LLM Mô hình Ngôn ngữ Lớn (Large Language Models)

IC Hệ số Thông tin (Information Coefficient)

SAF Nhà máy seed Alpha (Seed Alpha Factory)

CSA Confidence Score Agent (*agent* Điểm Tin cậy)

RPA Risk Preference Agent (*agent* Sở thích Rủi ro)

MLP Multi-Layer Perceptron (Mạng Perceptron Đa lớp)

OHLCV Open, High, Low, Close, Volume (Mở, Cao, Thấp, Đóng, Khối lượng)

VWAP Volume Weighted Average Price (Giá Trung bình theo Khối lượng)

SOTA State-of-the-art (Hiện đại nhất, Tiên tiến nhất)

MoE Mixture of Experts (Hỗn hợp Chuyên gia)

SSE Shanghai Stock Exchange (Sàn giao dịch Chứng khoán Thượng Hải)

CSI China Securities Index (Chỉ số Chứng khoán Trung Quốc)

SP Standard Poor's

Tóm tắt nội dung

Nhóm trình bày một framework ba giai đoạn mới, tận dụng các Mô hình Ngôn ngữ Lớn (Mô hình Ngôn ngữ Lớn (Large Language Models) (LLM)) trong một hệ thống *multi-agent* nhận biết rủi ro để tự động hóa việc tìm kiếm chiến lược trong tài chính định lượng. Phương pháp của nhóm nghiên cứu giải quyết tính dễ vỡ của các mô hình học sâu truyền thống trong các ứng dụng tài chính bằng cách: sử dụng các LLM được thiết kế prompt để tạo ra các alpha factor có thể thực thi trên nhiều dữ liệu tài chính đa dạng, triển khai đánh giá dựa trên *multi-agent* để lọc các yếu tố dựa trên tình trạng thị trường, chất lượng dự đoán trong khi duy trì sự cân bằng danh mục, và triển khai tối ưu hóa trọng số động thích ứng với điều kiện thị trường. Kết quả thực nghiệm cho thấy hiệu suất mạnh mẽ của chiến lược trong các chế độ thị trường Trung Quốc & Hoa Kỳ so với các tiêu chuẩn đã được thiết lập. Công trình của nhóm mở rộng khả năng của LLM sang giao dịch định lượng, cung cấp một kiến trúc có thể mở rộng để trích xuất tín hiệu tài chính và xây dựng danh mục đầu tư. framework tổng thể vượt trội đáng kể so với tất cả các tiêu chuẩn với lợi nhuận tích lũy 53,17% trên SSE50¹ (tháng 1 năm 2023 đến tháng 1 năm 2024), cho thấy hiệu suất điều chỉnh theo rủi ro vượt trội và khả năng bảo vệ khỏi suy giảm trên thị trường.

¹Chỉ số SSE 50 theo dõi hiệu suất của 50 cổ phiếu blue-chip vốn hóa lớn có ảnh hưởng nhất trên Sàn giao dịch Chứng khoán Thượng Hải.

1 Mở đầu

1.1 Bối cảnh nghiên cứu

Những tiến bộ gần đây trong Mô hình Ngôn ngữ Lớn (LLMs) và hệ thống *multi-agent* đang mở ra hướng tiếp cận mới cho tài chính định lượng, kết hợp khả năng hiểu ngữ cảnh của LLMs với năng lực mô phỏng thị trường của các *agent*. Các công trình như BloombergGPT, StockAgent và FinCon cho thấy LLMs không chỉ hỗ trợ mà còn đóng vai trò chủ động trong ra quyết định tài chính, đặc biệt khi kết hợp với cấu trúc đa tác tử để mô phỏng hành vi thị trường phức tạp.

Tuy nhiên, quá trình khai thác alpha hiện vẫn gặp ba thách thức chính: thiếu khả năng thích ứng với thị trường động, khó khăn trong tích hợp dữ liệu đa dạng, và hạn chế trong phản ứng với biến động thị trường. Nhằm khắc phục điều này, chúng tôi đề xuất framework LLM-driven, gồm ba thành phần: (1) Khai thác Alpha Linh hoạt với LLMs để sinh và tổ chức các yếu tố alpha từ dữ liệu tài chính đa phương thức; (2) Đánh giá Thị trường Đa phương thức bằng hệ thống *multi-agent* thực hiện kiểm định yếu tố trong nhiều bối cảnh; và (3) Tối ưu hóa Chiến lược Động, phân bổ trọng số phù hợp cho từng yếu tố dựa trên điều kiện thị trường.

Công trình này kết hợp chặt chẽ giữa học máy hiện đại và kiến thức tài chính, đóng góp: (1) một "nhà máy alpha" sử dụng LLMs; (2) một phương pháp quản lý danh mục *multi-agent* phản ứng theo điều kiện thị trường; và (3) một kiến trúc liên ngành mạnh mẽ cho chiến lược đầu tư tự động và thích ứng.

Khai thác alpha là quá trình khám phá các tín hiệu giao dịch tạo ra lợi nhuận vượt trội trên thị trường tài chính, nhóm xác định ba thách thức quan trọng trong khai thác alpha: Tính cứng nhắc của các phương pháp truyền thống thiếu khả năng thích ứng với thị trường năng động [19]; Thách thức về sự đa dạng và tích hợp dữ liệu bất chấp những tiến bộ của học máy [5, 24]; và Thích ứng với sự biến động của thị trường bất chấp những tiến bộ trong dự đoán [23] và xây dựng chiến lược [2].

framework LLM-driven của nhóm giải quyết những hạn chế này thông qua ba thành phần: Khai thác Alpha Linh hoạt (Flexible Alpha Mining) sử dụng LLM để trích xuất, phân loại và lọc các yếu tố alpha từ tài liệu tài chính, tổ chức chúng thành các yếu tố động lượng, cơ bản hoặc thanh khoản với tính độc lập đã được thiết lập [23]. Đánh giá Thị trường Đa phương thức *multi-agent* (Multi-agent Multimodal Market Evaluation) thực hiện kiểm định ngược (backtesting) nghiêm ngặt trên các điều kiện thị trường đa dạng, với các *agent* chuyên biệt đánh giá hiệu quả của yếu tố từ nhiều góc độ. Tối ưu hóa Chiến lược Động (Dynamic Strategy Optimization) triển khai một lớp cổng trọng số (weight gating layer) gán trọng số yếu tố alpha tối ưu dựa trên điều kiện thị trường hiện tại, đảm bảo phát triển chiến lược thích ứng.

Phương pháp luận của nhóm tổng hợp các kỹ thuật học máy tiên tiến với kiến thức chuyên môn về tài chính đã được thiết lập để tạo ra một framework mạnh mẽ cho việc xác định và tối ưu hóa alpha trên các loại tài sản đa dạng. Nghiên cứu này dựa trên các thực tiễn đầu tư định lượng thực nghiệm, kết nối những tiến bộ lý thuyết với các ứng dụng thực tế trong quản lý danh mục đầu tư.

1.2 Mục tiêu và phạm vi nghiên cứu

Mục tiêu chính của báo cáo này là tìm hiểu và trình bày một cách có hệ thống framework được đề xuất bởi Kou và cộng sự [11] cho việc tự động hóa tìm kiếm chiến lược đầu tư

định lượng sử dụng LLM và hệ thống *multi-agent*. Báo cáo sẽ tập trung vào:

- Phân tích cơ sở lý thuyết và phương pháp luận của framework.
- Trình bày các kết quả thực nghiệm và đánh giá hiệu suất của framework so với các phương pháp truyền thống và các mô hình State-of-the-art (Hiện đại nhất, Tiên tiến nhất) (SOTA) khác.
- Thảo luận về những đóng góp, hạn chế và hướng phát triển tiềm năng của nghiên cứu này.

Phạm vi nghiên cứu của báo cáo này dựa trên nội dung công bố của bài báo gốc, chủ yếu tập trung vào thị trường chứng khoán Trung Quốc (SSE50, CSI300) và Hoa Kỳ (SP500) trong các khoảng thời gian được chỉ định trong nghiên cứu gốc.

1.3 Hướng nghiên cứu chính và những đóng góp

Nghiên cứu của Kou và cộng sự [11] tập trung vào việc giải quyết các thách thức trong khai thác alpha truyền thống bằng cách tích hợp LLM và hệ thống *multi-agent*. Những đóng góp chính của nhóm nghiên cứu bao gồm:

1. Một framework mới để xác định các yếu tố alpha công thức bằng LLM, tận dụng khả năng khám phá của chúng để thiết lập một Nhà máy seed Alpha (Seed Alpha Factory) (SAF) từ thông tin đa phương thức với chức năng cập nhật tăng dần.
2. Giới thiệu một phương pháp *multi-agent* để quản lý danh mục đầu tư nhằm đánh giá mối quan hệ giữa điều kiện thị trường và các yếu tố alpha, cho phép đánh giá chuyên biệt theo các kịch bản khác nhau.
3. Tích hợp các kỹ thuật tiên tiến từ học máy và tài chính, thể hiện một bước tiến đáng kể trong việc phát triển các chiến lược đầu tư mạnh mẽ, thích ứng mà không cần sự can thiệp của con người.

Việc phân tích nghiên cứu này được thực hiện bởi nhóm sinh viên:

1. Nguyễn Thế Cường - Cơ sở toán học
2. Nguyễn Gia Huy - Phương pháp
3. Hoàng Văn Dương - Thực nghiệm

1.4 Cấu trúc báo cáo

Báo cáo này được tổ chức như sau:

- **Chương 1: Mở đầu** giới thiệu tổng quan về đề tài, bối cảnh, mục tiêu, phạm vi và đóng góp của nghiên cứu, cũng như cấu trúc của báo cáo.
- **Chương 2: Cơ sở lý thuyết** trình bày các khái niệm và nền tảng toán học liên quan đến yếu tố alpha, khai thác alpha và tối ưu hóa chiến lược trong đầu tư định lượng.

- **Chương 3: Phương pháp** mô tả chi tiết framework ba giai đoạn được đề xuất, bao gồm tạo seed alpha bằng LLM, đánh giá *multi-agent* đa phương thức và tối ưu hóa trọng số.
- **Chương 4: Thực nghiệm** trình bày thiết lập thực nghiệm, tập dữ liệu được sử dụng, các kết quả đánh giá hiệu suất của framework và so sánh với các phương pháp khác.
- **Chương 5: Kết luận** tóm tắt các kết quả chính, nêu bật những hạn chế của nghiên cứu và đề xuất các hướng phát triển trong tương lai.
- **Phân Tài liệu tham khảo**

2 Cơ sở lý thuyết

Nhóm xây dựng một framework giải quyết ba thách thức liên kết với nhau: toán học hóa các alpha này, phát triển các phương pháp động để tạo ra các seed alpha, và xác định cũng như tối ưu hóa các chiến lược yếu tố alpha. Phương pháp của nhóm tích hợp LLM và hệ thống *multi-agent* để khắc phục những hạn chế trong các phương pháp giao dịch định lượng truyền thống.

Nhóm sử dụng ký hiệu như sau: n cổ phiếu được quan sát trong các giai đoạn giao dịch $t \in 1, 2, \dots, T$, mỗi cổ phiếu được đặc trưng bởi m đặc điểm tài chính. Các yếu tố alpha được ký hiệu là $a_{ij}^{(t)}$ cho cổ phiếu i trong danh mục j tại thời điểm t , với trọng số tương ứng w_i . Điều kiện thị trường tại thời điểm t được biểu bằng $M^{(t)}$, và sức mạnh dự đoán của yếu tố alpha được đo bằng Hệ số Thông tin (IC)².

$$IC = \sigma(u, v) \quad (1)$$

Một IC cao hơn cho thấy mối quan hệ dự đoán mạnh mẽ hơn giữa các giá trị alpha và lợi nhuận trong tương lai, trong đó $\sigma(u, v)$ là hệ số tương quan giữa các alpha dự đoán u và lợi nhuận thực tế trong tương lai v .

2.1 Biểu diễn yếu tố Alpha

Vấn đề đầu tiên liên quan đến việc biểu diễn hiệu quả các yếu tố alpha bằng các biểu thức toán học nhằm nắm bắt các tín hiệu tài chính có ý nghĩa [13]. Cho các đặc điểm tài chính thô $X_i^{(t)} = \{X_{i1}^{(t)}, X_{i2}^{(t)}, \dots, X_{im}^{(t)}\}$ cho mỗi cổ phiếu i tại thời điểm t (chẳng hạn như giá, khối lượng và biến động), nhóm xác định các yếu tố alpha thông qua hai loại toán tử:

Toán tử Cắt ngang (Cross-Section Operators) f_{cs} : Các toán tử này xử lý dữ liệu từ một khoảng thời gian duy nhất, nắm bắt các mối quan hệ tức thời giữa các biến tài chính:

$$a_i^{(t)} = f_{cs}(X_i^{(t)}) \quad (2)$$

Toán tử Chuỗi thời gian (Time-Series Operators) f_{ts} : Các toán tử này phân tích dữ liệu trải dài nhiều khoảng thời gian, xác định các xu hướng và mô hình thời gian:

$$a_i^{(t)} = f_{ts}(X_i^{(t)}, X_i^{(t-1)}, \dots, X_i^{(t-n)}) \quad (3)$$

²IC là Hệ số Thông tin.

seed alpha cho cổ phiếu i trong danh mục j tại thời điểm t được xây dựng như sau:

$$a_{ij}^{(t)} = w_{cs} \cdot f_{cs}(X_i^{(t)}) + w_{ts} \cdot f_{ts}(X_i^{(t)}, \dots, X_i^{(t-n)}) \quad (4)$$

trong đó w_{cs} và w_{ts} là các trọng số được gán cho các thành phần cắt ngang và chuỗi thời gian tương ứng. Biểu diễn này cho phép kết hợp linh hoạt các tín hiệu tài chính khác nhau, cho phép tạo ra các yếu tố alpha phức tạp và tinh tế.

2.2 Khai thác và Lựa chọn Alpha

Thách thức thứ hai giải quyết những hạn chế của các phương pháp khai thác alpha truyền thống, vốn thường không thích ứng được với điều kiện thị trường thay đổi. nhóm xây dựng một phương pháp lựa chọn động để xác định các alpha phù hợp nhất với điều kiện thị trường hiện tại bằng cách sử dụng hai cơ chế đánh giá bổ sung:

Đánh giá Điểm Tin cậy (Confidence Score Evaluation): Đánh giá độ tin cậy thống kê của mỗi yếu tố alpha:

$$\theta_{ij} = E[IC(a_{ij}^{(t)} | M^{(t)})] \quad (5)$$

trong đó θ_{ij} biểu thị điểm tin cậy cho alpha a_{ij} , và $E[\cdot]$ biểu thị giá trị kỳ vọng. Điểm tin cậy cao hơn cho thấy hiệu suất nhất quán hơn trên các môi trường thị trường khác nhau.

Đánh giá Sở thích Rủi ro (Risk Preference Evaluation): Kiểm tra các đặc điểm rủi ro của mỗi yếu tố alpha:

$$\rho_{ij} = f_{\text{risk}}(a_{ij}^{(t)}, M^{(t)}) \quad (6)$$

trong đó ρ_{ij} biểu thị điểm rủi ro và f_{risk} là một hàm đánh giá mức độ hoạt động của alpha trong các kịch bản rủi ro khác nhau.

Tập hợp seed alpha tối ưu được lựa chọn bằng cách xem xét cả đánh giá tin cậy và rủi ro:

$$\alpha_{ij}^* = \arg \max_{a_{ij}} [w_c \cdot \theta_{ij} + w_r \cdot \rho_{ij}] \quad (7)$$

trong đó w_c và w_r là các trọng số được gán cho điểm tin cậy và điểm rủi ro tương ứng, phản ánh tầm quan trọng tương đối của chúng trong quá trình lựa chọn.

2.3 Tối ưu hóa chiến lược

Thách thức thứ ba liên quan đến việc kết hợp các alpha đã chọn thành một chiến lược đầu tư hiệu quả. Chiến lược alpha cuối cùng được xác định là một sự kết hợp có trọng số của các alpha tối ưu từ mỗi danh mục:

$$\alpha^{(t)} = \sum_{j=1}^k w_j \cdot \alpha_{ij}^{(t)} \quad (8)$$

trong đó w_j biểu thị trọng số được gán cho danh mục j , và k là tổng số danh mục alpha. Các trọng số này được điều chỉnh động dựa trên tình trạng thị trường hiện tại để tối đa hóa hiệu suất chiến lược trong khi quản lý rủi ro danh mục đầu tư tổng thể. Việc tối ưu hóa này hoàn thiện framework của nhóm, biến đổi dữ liệu tài chính thô thành một chiến lược giao dịch mạnh mẽ có thể thích ứng với môi trường thị trường thay đổi.


3 Phương pháp

3.1 Tổng quan về framework

framework gồm ba thành phần chính (xem Hình 1): (1) Nhà máy seed alpha (SAF), (2) Quy trình ra quyết định *multi-agent*, và (3) Cơ chế tối ưu hóa trọng số.

Giai đoạn đầu sử dụng LLMs để phân tích tài liệu tài chính đa phương thức, xây dựng SAF gồm các seed alpha chất lượng, được phân nhóm độc lập theo nguyên tắc khai thác alpha đã thiết lập [15]. Giai đoạn hai triển khai hệ thống *multi-agent* để đánh giá và chọn lọc alpha theo rủi ro và trạng thái thị trường, tạo ra tập hợp alpha thích nghi. Giai đoạn ba tối ưu hóa trọng số các alpha đã chọn bằng học sâu, hình thành chiến lược đầu tư mạch lạc.

Kiến trúc động của framework hỗ trợ cập nhật liên tục SAF theo nghiên cứu mới và điều kiện thị trường thay đổi, đảm bảo khả năng thích ứng và mở rộng cho nhiều thị trường tài chính toàn cầu.



Hình 1: Tổng quan về quy trình tạo chiến lược

3.2 Tạo seed alpha dựa trên LLM

Giai đoạn đầu triển khai quy trình lọc và phân loại dựa trên LLM cho các nghiên cứu liên quan đến alpha. Chúng tôi sử dụng mô hình GPT-4o để xử lý tập dữ liệu nghiên cứu tài chính đa dạng, bao gồm 11 tài liệu kết hợp cả khía cạnh lý thuyết và ứng dụng trong khai thác alpha.

Thông qua phân tích này, hệ thống đã tạo ra 9 danh mục riêng biệt với tổng cộng 100 seed alpha. Phương pháp tiếp cận giúp mô hình trích xuất chính xác các chi tiết và mối quan hệ phức tạp trong nghiên cứu tài chính, dẫn đến một SAF phong phú và có cấu trúc.

Đầu ra là tập hợp seed alpha đã được phân loại theo các lĩnh vực tài chính như Động lượng (Momentum), Đảo chiều trung bình (Mean Reversion), và Phân tích cơ bản (Fundamental Analysis), v.v. Mỗi danh mục đi kèm các chỉ định alpha cụ thể và công thức thực thi tương ứng được suy luận từ phân tích của LLM. Cấu trúc đầu ra này là nền tảng cho các giai đoạn xử lý tiếp theo.

3.3 Đánh giá *multi-agent* đa phương thức

Giai đoạn thứ hai triển khai một hệ thống đánh giá và lựa chọn toàn diện các yếu tố alpha thông qua một hệ thống đa phương thức và *multi-agent*. Hệ thống của nhóm tích hợp

năm loại dữ liệu đa phương thức bao gồm văn bản, số, hình ảnh, âm thanh và video. Kiến trúc *multi-agent* bao gồm hai *agent*: Confidence Score Agent (*agent* Điểm Tin cậy) (CSA) (*agent* Điểm Tin cậy) và Risk Preference Agent (*agent* Sở thích Rủi ro) (RPA) (*agent* Sở thích Rủi ro). Các yếu tố alpha được chọn sẽ trải qua quá trình kiểm định ngược (backtesting) nghiêm ngặt bằng cách sử dụng dữ liệu thị trường lịch sử, với các chỉ số đánh giá chính bao gồm IC [8] (phương trình 1) và Tỷ lệ Sharpe [17] (phương trình 9):

$$\text{Sharpe Ratio} = \frac{E[R(\alpha^{(t)}) - R_f]}{\sqrt{\text{Var}[R(\alpha^{(t)})]}} \quad (9)$$

trong đó $R(\alpha^{(t)})$ biểu thị lợi nhuận của chiến lược và R_f biểu thị lãi suất phi rủi ro. Nhóm đã phát triển một thuật toán Lựa chọn Alpha để tự động hóa việc lựa chọn. Thuật toán này xác định và lựa chọn một cách có hệ thống các alpha từ các danh mục khác nhau dựa trên điểm tin cậy của chúng, đảm bảo lựa chọn nghiêm ngặt các yếu tố đáp ứng ngưỡng tin cậy trên tất cả các danh mục trong khi duy trì sự đa dạng của danh mục.

3.4 Tối ưu hóa trọng số

Giai đoạn cuối cùng sử dụng một Multi-Layer Perceptron (Mạng Perceptron Đa lớp) (MLP) 3 lớp để tối ưu hóa trọng số của các seed alpha đã chọn bằng cách ánh xạ các tính toán alpha lịch sử với lợi suất trong tương lai [4]. Kiến trúc bao gồm một lớp đầu vào xử lý các giá trị alpha hàng ngày, một lớp ẩn với mười nút kích hoạt bằng ReLU, và một lớp đầu ra một nút để dự đoán lợi suất.

Trong quá trình huấn luyện, mạng sử dụng lan truyền ngược và gradient descent để giảm thiểu hàm mất mát, định lượng sự khác biệt giữa lợi suất dự đoán và lợi suất thực tế. Nhóm sử dụng một tập dữ liệu xác thực riêng biệt để đảm bảo khả năng khái quát hóa của mô hình và tránh overfitting. Deep Neural Network xử lý dữ liệu đầu vào thông qua lớp ẩn, biến đổi nó bằng các trọng số và độ lệch đã học, và tạo ra đầu ra cuối cùng thông qua trọng số, độ lệch và hàm kích hoạt của lớp đầu ra.

Phương pháp này thiết lập một framework mạnh mẽ để dự đoán lợi suất trong tương lai dựa trên các giá trị alpha lịch sử, chứng minh hiệu quả của các kỹ thuật học sâu trong việc tối ưu hóa trọng số alpha và nâng cao hiệu suất chiến lược đầu tư.

4 Thực nghiệm

Nghiên cứu của nhóm nhằm mục đích phát triển một framework khai thác alpha LLM-driven toàn diện hoạt động mà không cần sự can thiệp của con người. framework này có khả năng xử lý thông tin đa phương thức và thích ứng với các điều kiện thị trường thay đổi một cách độc đáo. Để xác nhận tính hiệu quả của framework, nhóm đã tiến hành một loạt các thí nghiệm.

4.1 Dữ liệu

Tập trung vào dữ liệu tài chính từ thị trường Trung Quốc và Hoa Kỳ, đặc biệt nhắm vào Chỉ số SSE 50. Bảng 1 cho thấy tập dữ liệu thử nghiệm, bao gồm sáu đặc điểm chính làm đầu vào ban đầu cho các yếu tố Alpha: mở cửa, cao, thấp, đóng cửa, khối lượng (Open, High, Low, Close, Volume (Mở, Cao, Thấp, Đóng, Khối lượng) (OHLCV)) và giá trung bình theo khối lượng (Volume Weighted Average Price (Giá Trung bình theo Khối lượng) (VWAP)).

Bảng 1: Tóm tắt Tập dữ liệu Thử nghiệm

Khía cạnh	Chi tiết
Primary Features	Mở, Cao, Thấp, Đóng, Khối lượng, VWAP
Alpha Factors	Các yếu tố tùy chỉnh dựa trên giá, khối lượng, tỷ số tài chính, trung bình động, phân tích tâm lý
Financial Reports	Báo cáo hàng quý và hàng năm từ các công ty thành phần của Chỉ số
Khoảng thời gian	Tháng 1 năm 2019 - Tháng 6 năm 2024
Phạm vi Thị trường	Chỉ số SSE50, CSI300, SP500
Tiêu chí Đánh giá	Mối quan hệ nhân quả, hiệu suất factor Alpha, độ mạnh mẽ của mô hình

4.2 Thiết lập thí nghiệm

Các thí nghiệm được thực hiện dựa trên các thiết lập được mô tả trong bài báo gốc [11]. Mô hình LLM chính được sử dụng là GPT-4o cho các tác vụ tạo và phân loại seed alpha.

4.3 Kết quả và Phân tích

4.3.1 Trích xuất kiến thức đa phương thức và khám phá Alpha thích ứng

Nhóm nghiên cứu triển khai một kiến trúc prompt (Hình 2) tích hợp thông tin thị trường đa phương thức vào LLM để trích xuất kiến thức toàn diện và lựa chọn seed alpha. Kiến trúc này tích hợp dữ liệu tài chính dạng văn bản, báo cáo tài chính công ty dạng số và biểu đồ giao dịch trực quan để cung cấp phân tích thị trường tổng thể. Cơ chế phân tích theo ngữ cảnh của nhóm điều chỉnh động các tham số dựa trên xu hướng thị trường hiện hành và hiệu suất ngành. Xác thực thực nghiệm cho thấy khả năng thích ứng của framework trên các điều kiện thị trường khác nhau.


Những kết quả này xác nhận khả năng của framework trong việc thích ứng động với các điều kiện thị trường thay đổi thông qua tích hợp dữ liệu đa phương thức hiệu quả. Khả năng thích ứng này cho phép xác định các alpha phù hợp với thị trường, nâng cao tính mạnh mẽ của chiến lược trên các môi trường thị trường đa dạng.

4.3.2 Hiệu suất so với các Alpha factor truyền thống

Khi đánh giá hiệu suất của các tín hiệu seed alpha đã chọn, chỉ số chính là IC. Nhóm nghiên cứu đã đánh giá năm loại alpha phổ biến nhất: Momentum, Mean Reversion, Volatility, Fundamental và Growth. Kết quả trong Bảng 2 cho thấy framework LLM-driven của nhóm liên tục đạt được các giá trị IC trung bình cao hơn trên tất cả các loại, đặc biệt là về Volatility và Fundamental, cho thấy hiệu quả giao dịch vượt trội so với bản gốc.

Bảng 2: IC Comparison of mean & selected

	Momentum	Mean Reversion	Volatility	Fundamental	Growth
Mean IC of SAF	0.0092	0.0135	0.0177	0.0118	0.0146
Mean IC of Selected SAF	0.0208	0.0187	0.0258	0.0192	0.0217



Hình 2: Alpha Được chọn Phụ thuộc vào Bối cảnh Khác nhau (Kiến trúc Prompt để lựa chọn Alpha thích ứng)


4.3.3 Đánh giá hiệu suất của Framework Alpha tích hợp thông qua việc so sánh với tham chiếu chuẩn

Bảng 3 trình bày một ví dụ về sự kết hợp của 12 alpha được tạo bởi framework của nhóm nghiên cứu, được đánh giá trên tập hợp cổ phiếu SSE50. Bảng chi tiết các seed alpha được LLM chọn từ mỗi danh mục, cùng với trọng số tương ứng và giá trị IC (phương trình 1). Giá trị IC của tổ hợp trọng số khá cao ở mức -0.0587. Mặc dù một số seed alpha riêng lẻ có giá trị IC tương đối thấp, việc loại bỏ chúng dẫn đến sự sụt giảm đáng kể trong trọng số tổ hợp được đào tạo lại, cho thấy vai trò quan trọng của chúng trong hiệu suất tổng thể. Ví dụ, nếu chúng ta loại bỏ alpha #6, tổ hợp trọng số sẽ giảm xuống -0.055; một khi chúng ta loại bỏ alpha #11, tổ hợp trọng số sẽ giảm xuống chỉ còn 0.0491. Điều này cho thấy tập hợp seed alpha được LLM chọn phối hợp hiệu quả, cung cấp sức mạnh dự đoán mạnh mẽ [27].

Nhóm đã tiến hành một thử nghiệm backtest sử dụng một phương pháp đầu tư đơn giản trong giai đoạn từ tháng 1 năm 2023 đến tháng 1 năm 2024 trên tập dữ liệu SSE50, nhóm tiến hành framework để xây dựng danh mục đầu tư. Diễn biến giá trị ròng của các chiến lược tương ứng trong giai đoạn thử nghiệm được thể hiện trong Hình 3, và ma trận so sánh được thể hiện trong Bảng 4. Mặc dù không tối ưu hóa rõ ràng cho lợi nhuận tuyệt đối, framework của nhóm cho thấy hiệu suất ấn tượng trong thử nghiệm backtest, đạt được lợi nhuận cao nhất so với các phương pháp khác. Lợi nhuận tích lũy của nhóm cho thử nghiệm backtest năm 2023 đạt 53,17% dương trong khi hiệu suất chỉ số là -11,73%. Phương pháp này chứng minh hiệu quả của framework LLM-driven của nhóm trong việc liên tục vượt trội so với các tiêu chuẩn thị trường thông qua sự thích ứng động với các điều kiện thay đổi.

Bảng 3: Kiểm tra Kết hợp 12 Alpha trên SSE50 năm 2023

#	Alpha	Weight	IC(SSE50)
1	(CLOSE - DELAY(CLOSE, 14))	-0.1459	0.0209
2	(RSI - DELAY(RSI, 14))	-1.0265	-0.0225
3	(CLOSE - DELAY(SMA(CLOSE, 14), 7))	-0.1978	0.0193
4	(MA(CLOSE, 20) - CLOSE)	0.0556	-0.0186
5	(SMA(CLOSE, 20) - CLOSE)	-0.945	-0.0186
6	(MAX(HIGH, 20) - CLOSE)	-0.4053	-0.0185
7	(100-RSI)	-0.3199	0.0194
8	(BOLL_UP - BOLL_DOWN) / SMA(CLOSE, 20)	3.6186	0.0278
9	STD(CLOSE, 10) / STD(CLOSE, 50)	-0.183	0.0236
10	VOLUME/MARKET_CAP	-3.2145	-0.0194
11	VOLUME * CLOSE	-0.0058	0.0187
12	(EPS/DELAY(EPS, 1) - 1)	-1.8351	-0.0215
Weighted Combination			-0.0587



Hình 3: Kết quả Backtest Lợi nhuận Tích lũy trên SSE50. Đường theo dõi giá trị ròng của các phương pháp khác nhau

Bảng 4: So sánh Hiệu suất của các Chiến lược Giao dịch

Chiến lược	Lợi nhuận cuối cùng (%)	Tỷ lệ Sharpe	Biến động (%)	Tỷ lệ Sortino	Tỷ lệ Calmar
Của nhóm	53.173	0.287	0.762	0.208	1.052
XGBoost [3]	9.532	0.038	1.019	0.067	0.103
LightGBM [9]	7.125	0.030	0.993	0.053	0.066
MLP	3.110	0.013	0.960	0.023	0.043
PPO_filter [16]	2.865	0.013	0.886	0.024	0.017
FinCon [25]	22.474	0.077	1.196	0.126	0.232
SEP [10]	17.891	0.060	1.217	0.103	0.157
SSE 50	-13.22	-0.063	0.859	-0.111	-0.043

4.3.4 Sức mạnh của Framework qua các giai đoạn

Nhóm đã tiến hành xác thực chéo nghiêm ngặt theo thời gian và thị trường, sử dụng hai bộ dữ liệu toàn diện từ các thành phần CSI300³ và SP500⁴, trong giai đoạn 01/2019–12/2023. Dữ liệu bao gồm giá OHLCV hàng ngày, báo cáo tài chính quý và các chỉ số kinh tế vĩ mô, được chia hệ thống thành tập huấn luyện, xác thực và thử nghiệm như Bảng 5. Thiết kế này cho phép đánh giá khả năng khái quát hóa của framework trên nhiều môi trường thị trường và thời gian.

Phân vùng thời gian được giữ nhất quán giữa hai thị trường để hỗ trợ so sánh. Kết quả (Bảng 6) cho thấy framework tạo alpha mạnh mẽ trên cả hai thị trường: trên A-share, lợi nhuận đạt 192,27% (so với 9,13%) trong nửa đầu 2023; tại Mỹ, lợi nhuận đạt 93,61% (2021 H1) và 118,24% (2023 H1). Ngay cả trong giai đoạn suy giảm (2022 H1), chiến lược vẫn sinh lời (12,78% ở CSI300, 2,77% ở SP500), vượt trội so với mức giảm của các chỉ số (-30,37%, -44,22%).

Bảng 5: Các giai đoạn Huấn luyện, Xác thực và Thử nghiệm cho CSI300 và SP500

Tài sản	Giai đoạn Huấn luyện	Giai đoạn Xác thực	Giai đoạn Thử nghiệm
CSI300	Tháng 1 2019-Tháng 6 2020	Tháng 7-Tháng 12 2020	Tháng 1-Tháng 6 2021
	Tháng 1 2020-Tháng 6 2021	Tháng 7-Tháng 12 2021	Tháng 1-Tháng 6 2022
	Tháng 1 2021-Tháng 6 2022	Tháng 7-Tháng 12 2022	Tháng 1-Tháng 6 2023
SP500	Tháng 1 2019-Tháng 6 2020	Tháng 7-Tháng 12 2020	Tháng 1-Tháng 6 2021
	Tháng 1 2020-Tháng 6 2021	Tháng 7-Tháng 12 2021	Tháng 1-Tháng 6 2022
	Tháng 1 2021-Tháng 6 2022	Tháng 7-Tháng 12 2022	Tháng 1-Tháng 6 2023

Bảng 6: Kết quả Hiệu suất Backtest qua các Cửa sổ Thời gian Khác nhau

Cửa sổ Thời gian	Lợi nhuận Hàng năm (%)		Lợi nhuận Tích lũy (%)		Max DD (%)	
	Chiến lược	Chỉ số	Chiến lược	Chỉ số	Chiến lược	Chỉ số
<i>Chiến lược của nhóm so với CSI300</i>						
Th1-Th6 2021	29.70	7.31	11.91	3.10	-19.40	-10.86
Th1-Th6 2022	12.78	-30.37	5.29	-14.37	-24.01	-28.59
Th1-Th6 2023	192.27	9.13	59.03	3.85	-17.03	-8.44
<i>Chiến lược của nhóm so với SP500</i>						
Th1-Th6 2021	93.61	29.67	35.19	12.59	-7.89	-4.23
Th1-Th6 2022	2.77	-44.22	1.25	-23.39	-20.55	-23.51
Th1-Th6 2023	118.24	35.22	42.78	14.76	-11.52	-7.75

Lưu ý: Max DD = Mức sụt giảm tối đa.

4.3.5 Nghiên cứu Ablation Study

Nghiên cứu loại bỏ thành phần của nhóm đánh giá một cách có hệ thống sự đóng góp của CSA và RPA trong một framework *multi-agent*. Nhóm đánh giá ba cấu hình của mỗi loại, sử dụng dữ liệu chỉ số SSE50 (2010-2022) và đo lường hiệu suất bằng IC (phương trình 1) và Tỷ lệ Sharpe (phương trình 9).

³Chỉ số theo dõi 300 công ty lớn tại Trung Quốc, truy cập qua Tushare API

⁴Chỉ số gồm 500 công ty lớn tại Mỹ, truy cập qua CRSP

Bảng 7 cho thấy mô hình hoàn chỉnh đạt được hiệu suất vượt trội, với IC ngoài mẫu là 0,047 và Tỷ lệ Sharpe là 1,94. Việc loại bỏ CSA gây ra sự suy giảm đáng kể, làm giảm IC ngoài mẫu 31,9% (từ 0.047 xuống 0.032) và Tỷ lệ Sharpe 22,2% (từ 1.94 xuống 1.51). Việc loại bỏ RPA cũng làm giảm các chỉ số hiệu suất, với tác động đặc biệt đáng kể đến Tỷ lệ Sharpe (giảm xuống 1.34). Những kết quả này cho thấy rằng trong khi cả hai thành phần đều đóng góp một cách có ý nghĩa, CSA đóng một vai trò quan trọng hơn trong việc duy trì sự ổn định dự đoán. Để đánh giá tính nhất quán của hiệu suất qua các điều kiện thị trường, nhóm đã phân tích các giá trị IC ngoài mẫu trong các chế độ thị trường khác nhau (Bảng 8). Mô hình hoàn chỉnh duy trì hiệu suất nhất quán qua các thị trường tăng giá, giảm giá và đi ngang. Ngược lại, mô hình không có CSA hoạt động đặc biệt kém trong các thị trường giảm giá (IC: 0,021 so với 0,042). Mô hình không có RPA cho thấy sự suy giảm vừa phải trong các thị trường không tăng giá, ít nghiêm trọng hơn so với quan sát khi không có CSA.

Phân tích này xác nhận rằng cả hai thành phần đều nâng cao sự ổn định hiệu suất, với CSA cung cấp chức năng đặc biệt quan trọng trong các điều kiện thị trường bất lợi.

Bảng 7: Kết quả Nghiên cứu Loại bỏ Thành phần: Tác động của các Thành phần *agent* lên các Chỉ số Hiệu suất

Cấu hình Mô hình	IC (Trong mẫu)	IC (Ngoài mẫu)	Tỷ lệ Sharpe
Mô hình Đầy đủ	0.059	0.047	1.94
Không có Điểm Tin cậy (CSA)	0.054	0.032	1.51
Không có Sở thích Rủi ro (RPA)	0.056	0.039	1.34

Bảng 8: Hiệu suất qua các Chế độ Thị trường (IC Ngoài mẫu)

Cấu hình Mô hình	Thị trường Tăng	Thị trường Giảm	Thị trường Đi ngang
Mô hình Đầy đủ	0.051	0.042	0.045
Không có Điểm Tin cậy (CSA)	0.046	0.021	0.029
Không có Sở thích Rủi ro (RPA)	0.049	0.028	0.037

4.3.6 Nghiên cứu độ nhạy

Nhóm đã phân tích độ nhạy của framework đối với trọng số *agent* và các siêu tham số mạng nơ-ron. Tỷ lệ trọng số CSA & RPA là 0,6/0,4 mang lại hiệu suất vượt trội qua các chế độ thị trường, đặc biệt là trong các thị trường giảm giá (Sharpe: 10,37), cho thấy khả năng phục hồi tốt hơn trước những thay đổi của chế độ (Bảng 9). Cấu hình mạng nơ-ron tối ưu (10 Hidden nodes, Learning rate: 0,001, batch size: 32, chính quy hóa: 0,001) đạt được tỷ lệ Sharpe là 13,33, với hiệu suất đặc biệt nhạy cảm với cường độ chính quy hóa (Bảng 10).

Phân tích cho thấy hành vi phụ thuộc vào chế độ qua các điều kiện thị trường và độ nhạy quan trọng đối với cường độ chính quy hóa. Cấu hình tối ưu đạt được tỷ lệ Sharpe tổng thể mạnh mẽ là 11,39.

Bảng 9: Độ nhạy với Cấu hình Trọng số *agent*

Trọng số		Tỷ lệ Sharpe		
Tin cậy (CSA)	Rủi ro (RPA)	Thị trường Tăng	Thị trường Giảm	Tổng thể
1.0	0.0	4.32	6.60	8.10
0.8	0.2	-3.41	-7.23	-2.68
0.6	0.4	8.70	10.37	11.39
0.5	0.5	-0.49	-1.62	-5.10
0.4	0.6	-4.27	-4.41	-8.04
0.2	0.8	5.68	8.51	9.00
0.0	1.0	-0.61	1.78	-4.35

Bảng 10: Độ nhạy với các Siêu tham số Mạng Nơ-ron

Hidden nodes	Learning rate	Batch size	Regularization Parameter	Sharpe Ratio
5	0.001	32	0.001	9.69
10	0.001	32	0.001	13.33
20	0.001	32	0.001	6.93
10	0.0005	32	0.001	7.03
10	0.002	32	0.001	5.13
10	0.001	16	0.001	6.26
10	0.001	64	0.001	4.25
10	0.001	32	0.0005	-1.88
10	0.001	32	0.002	-6.91

5 Kết luận

5.1 Tổng kết

Trong bài báo này, nhóm đã đề xuất một framework đầu tư định lượng mới tích hợp LLM và kiến trúc *multi-agent* để giải quyết sự bất ổn trong các phương pháp truyền thống. Hệ thống của nhóm tạo ra các yếu tố alpha đa dạng từ dữ liệu tài chính đa phương thức, xây dựng các *agent* giao dịch được hiệu chỉnh theo rủi ro, và sử dụng một cơ chế học sâu để điều chỉnh trọng số *agent* động dựa trên điều kiện thị trường.

Kết quả thực nghiệm xác nhận tính hiệu quả của framework trên các thị trường Trung Quốc và Hoa Kỳ, framework của nhóm cho thấy hiệu suất vượt trội đáng kể so với các phương pháp tạo alpha SOTA và các chỉ số chuẩn trên các chỉ số tài chính chính. Công trình này mở rộng thành công khả năng của LLM sang giao dịch định lượng, tạo ra một kiến trúc có thể mở rộng, thích ứng để trích xuất tín hiệu tài chính hoạt động hiệu quả mà không cần sự can thiệp của con người trên các chế độ thị trường đa dạng.

5.2 Hạn chế

framework của nhóm có một số hạn chế đáng kể. Thứ nhất, hiệu quả của hệ thống phụ thuộc vào chất lượng tài liệu đầu vào, có khả năng duy trì các sai lệch cố hữu [6, 1]. Thứ hai, các alpha do LLM tạo ra đôi khi thiếu trực giác tài chính đặc trưng của các nhà phân tích con người, dẫn đến các yếu tố hợp lý về mặt lý thuyết nhưng không khả thi

trong thực tế [20]. Thứ ba, phương pháp đánh giá *multi-agent* của nhóm giả định các mối quan hệ lịch sử bền vững giữa điều kiện thị trường và hiệu suất alpha—một giả định có thể tỏ ra mong manh trong các giai đoạn thay đổi chế độ thị trường. Cuối cùng, các nỗ lực xác thực của nhóm chủ yếu nhắm vào thị trường cổ phiếu, với khả năng áp dụng chéo tài sản đòi hỏi điều tra thực nghiệm bổ sung.

5.3 Hướng phát triển

Các hướng nghiên cứu trong tương lai nên giải quyết những hạn chế đã nêu bằng cách khám phá các kiến trúc Mixture of Experts (Hỗn hợp Chuyên gia) (MoE) (Hỗn hợp Chuyên gia) để cải thiện hiệu quả học tập [14], các kiến trúc *agent* thích ứng, các phương pháp học chuyển giao [21], và các triển khai hiệu quả về mặt tính toán. Cụ thể, có thể xem xét các cải tiến sau:

- Phát triển cơ chế kiểm soát chất lượng và giảm thiểu thiên vị cho dữ liệu đầu vào của LLM.
- Tích hợp kiến thức chuyên gia của con người vào quá trình tạo và lựa chọn alpha để tăng cường tính trực giác tài chính.
- Nghiên cứu các mô hình thích ứng với sự thay đổi chế độ thị trường một cách linh hoạt hơn.
- Mở rộng thử nghiệm và xác thực framework trên các loại tài sản khác (ví dụ: trái phiếu, hàng hóa) và các thị trường mới nổi.
- Mở rộng, ứng dụng vào thị trường Việt Nam

Tài liệu tham khảo

Tài liệu

- [1] Aditya Ashok, Manimaran Govindarasu, and Venkataramana Ajjarapu. 2018. Online detection of stealthy false data injection attacks in power system state estimation. *IEEE Transactions on Smart Grid*, 9(3):1636–1646.
- [2] Chi Chen, Li Zhao, Jiang Bian, Chunxiao Xing, and Tie-Yan Liu. 2019. Investment behaviors can tell what inside: Exploring stock intrinsic properties for stock trend prediction. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery Data Mining*, pages 2376–2384.
- [3] Tianqi Chen and Carlos Guestrin. 2016. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, San Francisco, CA, USA. ACM.
- [4] Yinpeng Chen and et al. 2020. Dynamic relu. In *European Conference on Computer Vision*. Springer International Publishing.
- [5] Can Cui, Wei Wang, Meihui Zhang, Gang Chen, Zhaojing Luo, and Beng Chin Ooi. 2021. Alphaevolve: A learning framework to discover novel alphas in quantitative investment. In *Proceedings of the 2021 International Conference on Management of Data (SIGMOD '21)*, pages 2208–2216, Virtual Event, China. ACM.
- [6] Chirag Deb, Fan Zhang, Junjing Yang, Siew Eang Lee, and Kwok Wei Shah. 2017. A review on time series forecasting techniques for building energy consumption. *Renewable and Sustainable Energy Reviews*, 74:902–924.
- [7] Yujie Ding, Shuai Jia, Tianyi Ma, Bingcheng Mao, Xiuze Zhou, Liuliu Li, and Dongming Han. 2023. Integrating stock features and global information via large language models for enhanced stock return prediction. *Preprint, arXiv:2310.05627*.
- [8] Thomas H Goodwin. 1998. The information ratio. *Financial Analysts Journal*, 54(4):34–43.
- [9] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. 2017. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017*, pages 3146–3154, Long Beach, CA, USA. Neural Information Processing Systems Foundation.
- [10] K. J. Koa, Y. Ma, R. Ng, and T.-S. Chua. 2024. Learning to generate explainable stock predictions using self-reflective large language models. In *Proceedings of the ACM on Web Conference 2024*, pages 4304–4315.
- [11] Zhizhuo Kou, Holam Yu, Junyu Luo, Jingshu Peng, Xujia Li, Chengzhong Liu, Juntao Dai, Lei Chen, Sirui Han, and Yike Guo. 2024. Automating Strategy Finding with LLMs in Quantitative Investment. *arXiv:2409.06289v3 [q-fin.PM]*.
- [12] Jean Lee, Nicholas Stevens, and Soyeon Caren Han. 2025. Large language models in finance (finllms). *Neural Computing and Applications*. (Anticipated publication)

- [13] Andrew W Lo. 2007. Where do alphas come from?: A new measure of the value of active investment management. *A new measure of the value of active investment management (May 8, 2007)*.
- [14] Saeed Masoudnia and Reza Ebrahimpour. 2014. Mixture of experts: a literature survey. *Artificial Intelligence Review*, 42:275–293.
- [15] OpenAI. 2023. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*.
- [16] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. 2017. Proximal policy optimization algorithms. *Preprint, arXiv:1707.06347*.
- [17] William F Sharpe. 1994. The sharpe ratio. *Journal of portfolio management*, 21(1):49–58.
- [18] Thomas Spooner and Rahul Savani. 2020. Robust market making via adversarial reinforcement learning. *Preprint, arXiv:2003.01820*.
- [19] Ziyi Tang, Zechuan Chen, Jiarui Yang, Jiayao Mai, Yongsen Zheng, Keze Wang, Jinrui Chen, and Liang Lin. 2025. Alphaagent: LLM-driven alpha mining with regularized exploration to counteract alpha decay. *Preprint, arXiv:2502.16789*. (Anticipated publication)
- [20] Suppawong Tuarob, Conrad S. Tucker, Soundar R. T. Kumara, C. Lee Giles, Aaron L. Pincus, David E. Conroy, and Nilam Ram. 2017. How are you feeling: A personalized methodology for predicting mental states from temporally observable physical and behavioral information. *Journal of Biomedical Informatics*, 68:1–19.
- [21] Liping Wang, Jiawei Li, Lifan Zhao, Zhizhuo Kou, Xiaohan Wang, Xinyi Zhu, Hao Wang, Yanyan Shen, and Lei Chen. 2023. Methods for acquiring and incorporating knowledge into stock price prediction: A survey. *arXiv preprint arXiv:2308.04947*.
- [22] Shijie Wu, Ozan Irsoy, Steven Lu, Vadim Dabravolski, Mark Dredze, Sebastian Gehrmann, Prabhanjan Kambadur, David Rosenberg, and Gideon Mann. 2023. Bloomberggpt: A large language model for finance. *Preprint, arXiv:2303.17564*.
- [23] Yumo Xu and Shay B Cohen. 2018. Stock movement prediction from tweets and historical prices. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1970–1979.
- [24] Shuo Yu, Hongyan Xue, Xiang Ao, Feiyang Pan, Jia He, Dandan Tu, and Qing He. 2023a. Generating synergistic formulaic alpha collections via reinforcement learning. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '23)*, pages 5476–5486, New York, NY, USA. Association for Computing Machinery.
- [25] Yangyang Yu, Zhiyuan Yao, Haohang Li, Zhiyang Deng, Yupeng Cao, Zhi Chen, Jordan W. Suchow, Rong Liu, Zhenyu Cui, Zhaozhao Xu, Denghui Zhang, Koduvayur Subbalakshmi, Guojun Xiong, Yueru He, Jimin Huang, Dong Li, and Qianqian Xie. 2024. Fincon: A synthesized llm *multi-agent* system with conceptual verbal reinforcement for enhanced financial decision making. *Preprint, arXiv:2407.06567*.

- [26] Chong Zhang, Xinyi Liu, Zhongmou Zhang, Mingyu Jin, Lingyao Li, Zhenting Wang, Wenyue Hua, Dong Shu, Suiyuan Zhu, Xiaobo Jin, Sujian Li, Mengnan Du, and Yongfeng Zhang. 2024a. When ai meets finance (stockagent): Large language model-based stock trading in simulated real-world environments. *Preprint, arXiv:2407.18957*.
- [27] Feng Zhang, Ruite Guo, and Honggao Cao. 2020. Information coefficient as a performance measure of stock selection models. *Journal of Asset Management*, 21:461-479.